

盘古 Pro MoE：昇腾原生的分组混合专家模型

华为盘古团队

日期：2025 年 5 月 28 日

摘要

混合专家模型 (MoE) 在大语言模型 (LLMs) 中逐渐兴起，该架构能够以较低计算成本支持更大规模的参数，从而获得更强的表达能力。这一优势源于其稀疏激活机制的设计特点，即每个输入 token 仅需激活部分参数即可完成计算。然而，在实际部署中，不同专家的激活频率存在严重的不均衡问题，一部分专家被过度调用，而其他专家则长期闲置，导致系统效率低下。为此，我们提出了新型的分组混合专家模型 (Mixture of Grouped Experts, MoGE)，它在专家选择阶段对专家进行分组，并约束 token 在每个组内激活等量专家，从而实现专家负载均衡，显著提升模型在昇腾平台的部署效率。基于 MoGE 架构，我们构建了总参数量 720 亿、激活参数量 160 亿的盘古 Pro MoE 模型，并针对昇腾 300I Duo 和 800I A2 平台进行系统优化。盘古 Pro MoE 在昇腾 800I A2 上实现了单卡 1148 tokens/s 的推理吞吐性能，并可进一步通过投机加速等技术提升至 1528 tokens/s，显著优于同等规模的 320 亿和 720 亿参数的稠密模型；在昇腾 300I Duo 推理服务器上，我们也实现了极具性价比的模型推理方案。我们的研究表明，昇腾 NPU 能够支持盘古 Pro MoE 的大规模并行训练，使其成为总参数量在千亿以下的领先模型¹。

1 引言

混合专家模型 (MoE) [1, 2, 3] 可以兼顾模型精度和效率，已经逐渐成为大语言模型 (LLMs) [4, 5, 6, 7, 8] 架构的主流方案。MoE 模型的核心设计理念是让每个 token 只需要激活部分专家参数，从而显著降低大语言模型的计算成本。但是专家负载不均衡的问题 [9, 10] 严重影响了实际中分布式训练和推理系统的计算效率。由于参数量庞大，大模型通常将参数分散部署在多个计算设备上。但在实际推理过程中，我们发现不同设备上的专家负载存在严重不均衡的问题。这种负载失衡在分布式环境下会造成严重后果。当不同专家分布在不同设备上时，整个系统的运行效率会被负载最重的设备拖累，不仅显著降低训练和推理速度，还会造成计算资源的浪费。

为解决设备间的专家不均衡问题，我们提出了图 1 所示的分组混合专家模型 (Mixture of Grouped Experts, MoGE) 的创新架构。此方案在专家选择阶段采用分组机制，具体来说，先将专家划分为若干等规模的分组，再从每个分组中选取相同数量的专家进行激活。在典型的分布式部署中，每个专家分组对应独立的计算设备，从而 MoGE 天然地实现了跨设备的计算负载均衡。这一设计显著提升了训练和推理场景下的系统吞吐量。

¹<https://gitcode.com/ascend-tribe/pangu-pro-moe>

英文技术报告: <https://arxiv.org/pdf/2505.21411>




图 1: MoGE 架构设计示意图。路由专家被均匀划分为 M 个不重叠的组，其中每个组内的专家将被分配到同一个设备上。对于每个输入特征，MoGE 首先通过全局 softmax 路由器计算所有专家的门控得分。接着，在每个专家组内，根据这些得分选出 $K' = K/M$ 个得分最高的专家（图中为从每组 4 个专家中选取 2 个）。未被选中的专家，其对应权重被置为 0。最终 MoGE 的输出由被激活专家的输出和共享专家的输出加权求和得到。

基于 MoGE 架构，我们构建了总参数量 720 亿、激活参数量 160 亿的盘古 Pro MoE 模型。通过昇腾平台的大量仿真实验，我们优化了模型配置，使其可以在昇腾 300I Duo 和 800I A2 等 NPU 平台上取得最优性能。为进一步加速推理效率，我们也从系统、算法和算子三个层面，对盘古 Pro MoE 的推理进行了全方位优化。1) 在系统层面，基于模型结构与昇腾互联拓扑的协同设计，我们提出了一种分层混合并行与通信优化策略，该方案显著降低了冗余计算和通信开销；2) 在算法层面，我们采用量化压缩等优化技术进一步减少计算量；3) 在算子层面则专门开发了面向昇腾 NPU 定制的高性能 MulAttention 和 SwiftGMM 算子。在昇腾 800I A2 平台上，盘古 Pro MoE 展现出卓越的性能优势，在低并发场景下实现了低延迟，在高并发场景下实现了高吞吐，优于 32B 和 72B 等同类别的稠密模型。在昇腾 300I Duo 平台上，通过软硬协同优化，盘古 Pro MoE 可以实现极致的推理性价比。

基于 13 万亿 token 的高质量多源语料库，盘古 Pro MoE 首先使用 4K 块昇腾 NPU 进行大规模预训练，然后再通过监督微调（Supervised Fine-Tuning, SFT）和强化学习（Reinforcement Learning, RL）进一步提升模型的推理能力。多项公开基准测试结果表明，盘古 Pro MoE 在千亿内总参数量模型中处于领先地位。

2 分组混合专家模型

本章介绍一种全新 MoE 架构：分组混合专家模型（Mixture of Grouped Experts, MoGE），该架构旨在从路由机制上实现跨设备的计算负载均衡。MoGE 的核心思想是将所有专家均匀地划分为若干组，每组分配到一个具体的设备上，并在路由过程中强制每个 token 从各组中选择相同数量的专家进行激活。接下来我们将首先回顾传统 MoE 架构中存在的专家负载不均衡问题，随

后详细介绍 MoGE 的架构设计、路由机制以及相应的辅助项损失函数。

2.1 专家负载均衡问题

设 $X \subseteq \mathbb{R}^d$ 为输入特征空间, MoE 通常由 N 个不同的专家网络组成, 记作 $\{E_1, E_2, \dots, E_n\}$, 其中各专家 $E_i: X \rightarrow \mathcal{Y}$ 将输入特征映射到一个输出空间 $\mathcal{Y}$ 。对于给定的输入 $\mathbf{h} \in X$, MoE 模块的输出表示为这 N 个专家网络输出的加权和:

$$\mathbf{y} = \sum_{i=1}^N G(\mathbf{h})_i \cdot E_i(\mathbf{h}), \quad (1)$$

其中, $G(\mathbf{x})_i$ 表示第 i 个专家 E_i 的专家权重, 该分数决定了该专家对最终输出的贡献度。为了得到 $G(\mathbf{h})$, 我们首先对路由矩阵 $\mathbf{W} \in \mathbb{R}^{d \times n}$ 和 $\mathbf{h}$ 的内积相似度进行 Top-K [1] 筛选, 然后对结果执行 softmax 操作:

$$G(\mathbf{h}) = \text{Softmax}(\text{TopK}(\mathbf{W}^\top \mathbf{h}, K)),$$

$$\text{TopK}(\mathbf{v}, k) = \begin{cases} v_i, & \text{若 } v_i \text{ 属于 } \mathbf{v} \text{ 中最大的 } k \text{ 个元素,} \\ -\infty, & \text{否则.} \end{cases} \quad (2)$$

其中, $\text{Softmax}(\mathbf{u}) = \exp(u_i) / \sum_i \exp(u_i)$ 表示标准的 softmax 运算, K 表示每个 token 所激活的专家数量。TopK($\mathbf{v}, k$) 则表示从向量 $\mathbf{v}$ 中选出最大的 k 个元素并保留其值, 其余置为 $-\infty$ 。在该路由机制中, 非 Top-K 专家权重被置为 $G(\mathbf{h})_i = 0$, 相关运算被跳过, 实现了专家的稀疏激活。

在实际部署中, 这 N 个专家通常会被均匀地分布到 M 个计算设备 (例如 NPU) 上以实现并行处理, 特别是针对大规模参数的模型。然而, 公式 (2) 中标准的 Top-K 路由机制并未对被选中的 K 个专家的位置加以约束。因此, 对于某个给定的 token, 所选的 K 个专家有可能会集中在少数几个设备上, 如图 2(a) (左图) 所示。

这种被激活专家在设备间的不均匀分布带来了严重的负载不均衡问题。当某些设备上的专家被频繁激活时, 这些设备需处理更多的 token, 而其他设备则可能处于空闲或低负载的状态。此种不均衡带来了“拖慢者”效应, 即系统整体的推理速度受到最慢 (最繁忙) 设备的限制, 导致计算资源利用效率下降, 并显著增加整体推理时延。

为了量化这种设备间的负载不均衡, 我们引入了不均衡程度 (Imbalance Score, IS) 的概念。假设模型正在处理一组输入 Tokens 集合 X , 令 $T_i(X)$ 表示第 i 个设备上的专家计算量 (被路由到该设备上的 token 数)。IS 被定义为所有 M 个设备中最大与最小专家计算量之差, 并且按照总 tokens 数 $|X|$ 进行归一化处理的结果, 即:

$$IS(X) = \frac{1}{|X|} \left[\max_{i \in 1, \dots, M} T_i(X) - \min_{i \in 1, \dots, M} T_i(X) \right]. \quad (3)$$

IS 值越大, 表示设备间的负载不均衡越严重; 反之, 若 IS 等于 0, 则说明每个设备处理的计算量完全相同, 负载达到了最佳均衡状态。直观上, 即使设备的平均负载比较理想, 高 IS 依然意味着部分设备过载而部分设备处于空闲, 整体系统效率较低。因此, IS 能够反映出系统中是否存在由于设备间的负载不均衡导致的性能瓶颈。

为了分析 Top-K 路由策略带来的负载不均衡, 我们对其 IS 的分布进行估计。简单起见, 我们假设每个 token 的 K 个专家是从 N 个专家中独立且均匀地随机选择的, 并采用蒙特卡洛 (Monte Carlo) 方法对不均衡程度分布进行估计。给定一组参数, 我们可以重复模拟专家路由过程 D 次,




图 2: 传统 Top-K 路由与 MoGE 分组均衡路由在专家激活模式与负载均衡方面的比较。(a) 展示了两种路由策略在单个输入 token 下的专家选择情况。在该示例中，从总共 24 个专家中激活 8 个专家，并采用 4 路专家并行。在 Top-K 路由中（左图），所选的 8 个专家在设备间分布不均，例如设备 1 上没有任何专家被选择，而设备 2 则有 4 个专家被激活，导致明显的设备间负载不均衡。相比之下，MoGE（右图）从每组中固定选择 2 个专家，确保各设备间负载均衡。(b) 展示了两种路由机制下不均衡程度（IS）的概率分布估计。较低的 IS 值表示更好的负载均衡。由于 MoGE 的分组均衡设计，其在结构上保证了 IS 恒为 0，实现了天然的设备间负载均衡。

每次计算 IS 值。那么，某一特定 IS 值 v 出现的概率可近似为：

$$P(IS = v) = \frac{1}{D} \sum_{j=1}^D \mathbb{I}(IS(X_j) = v), \quad (4)$$

其中 X_j 表示第 j 次模拟生成的 Tokens 集合， $\mathbb{I}(\cdot)$ 为指示函数。图 2(b)（右图，蓝色柱状图）展示了在 $N = 64$ ， $K = 8$ ， $M = 8$ 以及 $|X| = 16$ 的条件下估计得到的 IS 分布情况。图中显示 $IS > 0$ （存在不均衡）的概率接近 1，说明使用标准 Top-K 路由大概率会触发设备间负载不均问题。

2.2 分组混合专家的架构设计

为直接解决传统 MoE 架构中固有的设备间负载不均衡问题，我们提出了一种新的架构：分组混合专家模型（Mixture of Grouped Experts, MoGE），该架构创新性地采用了分组均衡路由策略以实现设备间负载均衡。其核心思想是：将每个 token 的激活专家在所有设备之间进行等量分配，在设计上确保公式 (3) 中的不均衡程度天然为 0，如图 2(b) 中的黄色单柱所示。

架构设计 图 1 展示了 MoGE 的架构，它通过以下两个策略来实现设备间的负载均衡：1) 专家分组（Expert Partitioning）：将所有的 N 个专家确定性地划分为 M 个互不重叠的组。每组专家（例如第 j 组， $j = 1, 2, \dots, M$ ）包含 $N_g = N/M$ 个专家。需要注意的是，一组专家通常被分配到一个特定的计算设备上；2) 分组均衡路由（Group-Balanced Routing）：对于每个输入 $\mathbf{h}$ ，路由机制会从每组专家中固定激活 $K' = K/M$ 个专家。此时，每个 token 激活的专家总数仍为 K ，但是每个设备上的被激活专家的数量被严格限定。

首先，MoGE 基于 $\mathbf{h}$ 与路由权重矩阵 $\mathbf{W} \in \mathbb{R}^{d \times n}$ 通过全局 softmax 操作计算所有 N 个专家的归一化权重 $\mathbf{S}$ ：

$$\mathbf{S} = \text{Softmax}(\mathbf{W}^\top \mathbf{h}), \quad (5)$$

其中， $\mathbf{S}$ 是一个大小为 N 的一维向量， S_i 表示输入专家 E_i 的初始权重。

其次，不同于直接在所有专家上执行 Top-K 操作，我们在每个组内通过局部的 Top-K 操作来进行专家选择。记 S_j 表示 S 中的一个子向量，包含第 j 组的 $N_g = N/M$ 个专家的权重。在每个专家组 j 内，我们执行一次局部 Top- K' 操作。将所有的局部 Top- K' 结果拼接，便得到 MoGE 的专家权重 $G'(\mathbf{h})$ ，如下所示：

$$G'(\mathbf{h}) = (\text{TopK}(S_1, K'), \dots, \text{TopK}(S_M, K')). \quad (6)$$

基于这种机制，每个专家组 j 中权重最高的 K' 个专家被激活，其余权重设为 0。盘古 Pro MoE 中使用的是 $K' = 1$ 的特殊情况，即每个专家分组中仅激活一个专家，详细配置间见表 1。

最后，MoGE 的输出 $\mathbf{y}_{\text{MoGE}}$ 与公式 (1) 中标准 MoE 的计算方式相似：

$$\mathbf{y}_{\text{MoGE}} = \sum_{i=1}^N G'(\mathbf{h})_i \cdot E_i(\mathbf{h}). \quad (7)$$

均衡辅助损失 尽管 MoGE 从结构上天生的保证了组间的负载均衡，但仍需确保路由模块能够在每一个组内合理的调节专家的负载。我们使用 batch 粒度的负载均衡损失：

$$\ell_{\text{aux}} = \alpha \sum_{i=1}^N f_i p_i,$$

其中，超参数 α 控制辅助损失的强度， f_i 表示 batch 内被路由到专家 i 的 token 占比， p_i 是专家 E_i 在 batch 中的平均门控得分，定义为：

$$f_i = \frac{N}{K|\mathcal{B}|} \sum_{t \in \mathcal{B}} \mathbb{I}\{\text{token } t \text{ 被路由到专家 } E_i\}, \quad p_i = \frac{1}{\mathcal{B}} \sum_{t \in \mathcal{B}} S_{i,t}, \quad (8)$$

其中， $\mathbb{I}\{\cdot\}$ 是指示函数， $S_{i,t}$ 表示 token t 上专家 E_i 的门控得分。实验发现，使用全局的 softmax 权重 S 整体地计算辅助均衡损失，会比每个组独立且局部的进行路由和损失计算效果更优。

综上，模型的总训练损失函数定义为：

$$\ell_{\text{total}} = \ell_{\text{MoE}} + \lambda \ell_{\text{aux}},$$

其中， ℓ_{MoE} 表示标准 MoE 的损失函数如交叉熵损失，超参数 λ 控制辅助损失的强度。

2.3 模型架构仿真

本节重点介绍昇腾亲和模型关键超参数的确定方法。在模型设计过程中，我们采用一种分层设计策略，通过从粗粒度到细粒度的渐进式调优，平衡模型精度和昇腾 300I Duo 和 800I A2 平台上的推理效率。该策略分为三个阶段：1) 首先，依据服务器内存总带宽和时延约束确定粗粒度的参数范围；2) 其次，基于领域知识对潜在模型进行候选集缩减，缩小设计空间；3) 最后，利用算子级仿真器评估候选模型性能。该仿真器关联系统硬件参数（如 TFLOPS、内存访问带宽、内存容量及互连拓扑）并自动搜索最优并行策略。

图 3 展示了候选模型的仿真评估结果。所有候选模型的配置均在以下参数范围内：隐藏层大小 (4096-8192)、Query 头数 (32-64)、KV 头数 (8-16)、层数 (40-64) 以及路由专家数 (32-64)，总参数量在 60B-80B 之间。

在解码阶段，模型的推理性能主要受限于内存访问和通信开销。其中，模型结构对通信效率影响显著。例如，隐藏层大小决定了单次通信的数据量，层数则决定了通信频率。通过考虑系统的静态通信延迟与可用带宽，可对这两者之间的权衡进行有效评估。从内存访问角度来看，




图 3: 候选模型配置的仿真结果。图中展示了不同配置的模型在 Ascend 300I Duo 与 800I A2 平台上分别满足 100 毫秒与 50 毫秒 TPOT (Time To First Token) 约束下的吞吐量表现。所有结果均相对于随机选取的一组候选配置进行了归一化处理。

在参数总量一致的条件下，更高的稀疏率能够在相同并发场景下减少需要加载的参数量。通过分层设计策略与细粒度仿真，最终盘古 Pro MoE 选取图 3 中橘黄色星号标记的模型，该模型在当前设计条件下对 Ascend 300I Duo 和 800I A2 平台表现出最佳亲和性，具体超参配置见表 1。

3 模型训练

在本章中，我们将阐述盘古 Pro MoE 的训练整体流程。我们的训练流程中包含两个关键阶段：预训练和后训练。每个阶段使用特定的训练策略和数据课程设计，旨在逐步提升模型的理解能力和逻辑推理能力。

3.1 预训练

我们首先将详细说明预训练阶段所使用的数据构成，重点阐述其与模型能力构建过程的相关性。随后，我们将介绍确保模型稳定收敛的预训练策略。

3.1.1 数据构成

盘古 Pro MoE 的预训练数据集共包含 13T 个经过我们分词器分词得到的 token，分词器词表的大小为 153376。该分词器采用领域感知的词汇构建策略，旨在保持不同领域之间的均衡表征 [8]。该数据集整合了多源多样的高质量内容，其中来源包括网页文本、书籍文献、多语言数据、代码、STEM（科学、技术、工程与数学）领域数据、工业领域数据、推理数据以及合成数据等。

表 1: 盘古 Pro MoE 模型配置。

配置	盘古 Pro MoE
词表大小	153376
隐藏层大小	5120
中间层大小	1344
Query 头数	40
KV 头数	8
头大小	128
层数	48
路由专家	64
激活专家	8
共享专家	4
激活参数量 (B)	16.50
总参数量 (B)	71.99

训练阶段 盘古 Pro MoE 的整体预训练过程被划分为三个循序渐进的阶段：通用阶段 (9.6T)、推理阶段 (3T) 和退火阶段 (0.4T)。这三个阶段旨在逐步提升盘古 Pro MoE 的核心能力：第一阶段重点培养通用知识与语言能力，第二阶段着重增强模型推理技能，第三阶段则进一步优化模型知识与行为范式。除整合多源通用数据外，我们在通用阶段特别引入了多个工业领域的大量高质量数据。整体训练参数上，第一阶段采用 4K 序列长度，后两个阶段提升至 32K 序列长度。

在第二阶段推理阶段，我们通过大幅提升 STEM、代码以及内部构建的更复杂数据的比例，针对性增强盘古 Pro MoE 的推理能力。为此，我们着重优化了数据清洗、数据生成与数据评估的全流程，确保推理数据的规模与质量。针对困难样本，我们特别设计了短思维链与长思维链的合成数据，并采用 32K 序列长度以适配长思维链推理输出的需求。相较于前代模型 [8, 11]，盘古 Pro MoE 训练时使用了覆盖范围更广的高质量推理数据，这使得其在相对较小的模型规模下仍能保持优异性能。

第三阶段退火阶段旨在实现从预训练到后训练的过渡，该阶段指令风格数据占比提升至训练语料的约 20%。在此阶段，我们优先选取具有极高质量与高难度的数据，遵循在三个阶段课程难度逐渐提升的数据采样策略。我们还特意增加了高阶 STEM 教育相关数据的比重，使其总量达到训练语料的 18%。通过使用 70 亿参数的代理模型，我们针对该阶段的数据选择与数据配比进行了密集的消融实验，以评估不同策略对模型的影响。训练结果表明，通过采用恰当的数据配比与衰减学习率，该第三阶段仍能显著提升模型性能。

数据评估 我们采用基于模型的领域感知评估方法持续监控并提升训练语料质量，该方法通过微调盘古系列的模型作为评估器实现。具体来讲，我们在微调过程中为不同领域设计了带标注的数据集，从而构建了多个领域感知评估器。在小型代理模型上进行的消融实验表明，该数据评估系统相比单一通用评估器能产生更优的评估性能。所有数据样本均需通过该评估系统，并在清洁度、流畅度、教育价值及丰富度多个维度进行打分，这些评分将直接用于我们的数据选择与采样策略。

此外，每个数据样本均被赋予一个类别标签，共计 188 个类别。该数据标签充当分类器的角色，不仅便于数据的分类与分组，更重要的是能以细粒度方式优化数据混合比例，并确保训练语料库在各主题之间有一个合理分布。

3.1.2 预训练参数

在预训练阶段，我们采用 AdamW 优化器 ($\beta_1 = 0.9$, $\beta_2 = 0.95$) 对模型进行单轮训练，全程采用余弦学习率调度并包含三个渐进阶段。在通用阶段，学习率从 3×10^{-4} 衰减至 3×10^{-5} ，batch size 为 400 万 token；随后进入推理阶段，学习率进一步从 3×10^{-5} 降至 1×10^{-5} ，同时将 batch size 提升至 1600 万 token 以增强复杂推理任务的训练效果；最终在退火阶段，学习率从 1×10^{-5} 逐步衰减至 1×10^{-7} ，并维持 1600 万 token 的 batch size 以确保稳定收敛。这种结构化的多阶段训练策略有效实现了不同学习目标间的鲁棒泛化与专项优化的协同提升。

3.2 后训练对齐

监督微调 盘古 Pro MoE 的监督微调数据被划分为推理与非推理两个子集，为了增强模型的推理能力，我们控制其采样比例为 3:1。具体而言，推理部分主要包含数学解题、代码生成和逻辑推理等任务；而非推理部分则侧重于通用语言指令遵循、问答、文本生成、长上下文理解、语义分类以及工具使用等任务。推理密集型任务，尤其是涉及多步计算、符号操作或形式逻辑的任务，在指令微调语料库中往往代表性不足，然而这些任务对于大型语言模型慢思考能力的涌现至关重要。通过对此类任务数据赋予更高比重，我们旨在显式地促进模型学习到鲁棒的中间步骤推理能力以及超越浅层模式匹配的深层认知表征。针对每个子领域，我们采用了一种简单有效的基于多样性的度量指标 [12]，从大量高质量、专家筛选的和合成的指令数据中选取具有代表性的指令。这种多样化任务的数据组合构成了一个多维训练空间，旨在提升模型在专用任务和通用任务上的泛化能力。

此外，该训练采用两阶段渐进式优化策略，分六个训练轮次进行，两个阶段的全局 batch size 分别为 64 和 32。这种分阶段设计实现了类似课程学习的过程：模型初期专注于广泛的指令遵从，随后通过更精细的梯度更新逐步过渡到复杂推理任务的掌握。这种渐进式训练方案不仅能稳定收敛过程，还能在后期强化推理任务时有效减少灾难性遗忘现象。从慢思考模型的角度来看，这种设计提供了两个关键优势，可使模型具有更强的推理能力：其一，在训练早期强化推理能力能建立针对逐步问题解决的归纳偏置；其二，分阶段微调使模型在应对更高认知要求的任务前，巩固其通用语言能力。这种设计使模型在整体的流畅性与思考深度之间权衡，从而在需要缜密多步推理的评测集上实现性能提升。参数更新采用 AdamW 优化器，其中权重衰减系数设为 0.1。学习率遵循余弦衰减算法，从初始值逐渐下降，至训练结束时降至峰值学习率的 10%。两个阶段的学习率分别初始化为 $1e-5$ 和 $3e-6$ ，通过这种分阶段学习率调度方法在收敛速度与训练稳定性之间取得平衡。

模型融合 模型融合已被证明是一种整合模型的多样化任务能力并增强泛化性能的有效技术。现有的研究主要集中于异构模型的合并，例如整合通过不同数据混合比例或超参数训练的监督微调模型。在已有发现的基础上，我们探索了一种新范式：融合来自单次监督微调训练中同源的 checkpoints。我们的方法通过整合同一训练过程中不同阶段保存的检查点，利用其隐含的互补行为来提升最终模型的鲁棒性与泛化能力。

具体而言，我们首先根据训练阶段对所有中间 checkpoints 进行分组，并以训练轮次作为划分依据。同一训练轮次内保存的 checkpoints 归为同一组，从而确保每一组既能捕捉独特的行为特征，又能保持时间一致性。随后，我们对监督微调 checkpoints 与初始基座模型参数之间的增量参数进行加权聚合。与现有方法不同，我们采用双层合并策略：1) **组内融合**：首先对每组内基于训练轮次的增量参数进行聚合；2) **组间融合**：再将各组生成的轮次级增量参数跨组融合，得到最终的模型参数。通过应用该融合方法，我们能够有效整合不同训练阶段的互补性知识。

从数学形式上看，合并后的模型参数可通过以下公式表示：

$$\Theta_{merged} = \Theta_{base} + \sum_{k=1}^K \lambda_k \sum_{i=1}^{N_k} \frac{1}{N_k} (\Theta_i^k - \Theta_{base}), \quad (9)$$

其中， Θ_{merged} 表示最终合并的模型参数， Θ_{base} 表示监督微调训练初始阶段的模型参数， N_k 是

第 k 个分组中的 checkpoint 数量, Θ_i^k 表示第 k 个分组中第 i 个 checkpoint 的模型参数.

强化学习 在强化学习训练阶段, 我们采用当前主流算法 GRPO 进行模型训练. 当同一问题生成的所有回复均获得相同奖励时, 会出现一个关键问题: 此时归一化优势函数将为零, 进而导致 GRPO 目标函数退化为单纯的行为克隆损失, 从而抑制策略探索. 为解决这一问题, 我们提出了零优势掩码 (Zero-Advantage-Mask) 机制. 该机制通过屏蔽优势函数为零的样本对损失的影响, 确保策略更新仅由具有明确学习信号 (即优势不为零) 的“有效数据”驱动, 从而增强策略探索与学习的稳定性.

为提供准确且任务自适应的奖励信号, 我们采用了一种多源奖励系统, 该系统能根据任务特性动态地将提示词及其生成的回复路由至相应的奖励评估模块. 该系统包含三个核心组件:

- **正确性奖励**: 针对具有真实标签的任务 (如数学、编程), 系统分配基于正确性的奖励. 数学问题通过规则 + 大模型的混合评估体系进行验证, 其中标准题型采用基于规则的打分, 复杂题型则使用基于大语言模型的裁判来做准确的打分. 代码数据则会经历多阶段评估流程: 代码提取、语法校验、在线解释器执行及测试用例比对, 其奖励可以是分层式的 (阶梯离散奖励) 或基于通过率的 (连续奖励).
- **偏好奖励**: 在开放任务中, 当无法获取真实标签 (例如创意写作) 时, 系统会引入偏好奖励模型. 该模型是一个经过人类偏好数据训练的大语言模型, 针对通用开放性问题进行打分, 输出标量打分值。。
- **辅助奖励**: 奖励系统还包括辅助奖励, 其中格式辅助奖励对违反预定义结构要求的回答进行惩罚, 基于字符串哈希值的轻量级重复惩罚奖励可以抑制过于冗长或重复的输出. 这些辅助奖励与上述两种主要奖励信号组合运行, 能够在不改变主要学习目标的情况下保证输出质量.

为提高训练效率与效果, 我们采用了一种课程数据混合策略. 当一批数据都过于简单 (始终生成正确回复) 或过于困难 (始终生成错误回复) 时, 其对应的奖励信号对 GRPO 算法提供的学习信号有限, 却仍消耗计算资源. 我们的课程学习方法通过模型感知的方式评估数据复杂度: 让当前大语言模型针对每个提示生成多个回复, 对于可验证任务以通过率作为复杂度指标, 对于不可验证任务则以损失值作为判断依据. 通过率越低或损失值越高, 表明任务复杂度越高. 在训练过程中, 系统动态调整不同复杂度样本的混合比例, 逐步向模型提供经过优化的数据组合. 这种渐进式课程设计确保模型持续获得有意义的奖励信号, 从而实现更高效的策略更新.

4 训推系统

4.1 针对昇腾 NPU 优化的训练系统

我们对盘古 Ultra MoE [11] 提到的加速技术进行了进一步的优化来提升性能. 这些优化包括: 通信开销更小的分层 EP All-to-All 通信 (Hierarchical EP All-to-All Communication); 自适应流水掩盖机制 (Adaptive Pipeline Overlap Mechanism) 中更细粒度的算子调度和更高效的掩盖; 以及在内存优化策略中新增的细粒度可配置重计算和 swap 模块. 这些优化策略不仅提高了盘古 Ultra MoE 的模型算力利用率 (MFU) (具体细节后续发布), 而且能够适配到盘古 Pro MoE, 大

表 2: 基线和加速特性优化后的 MFU 对比。

	并行策略	加速特性	MFU
基线	TP1, EP8, CP8, PP6, VPP4	-	-
优化后	TP8, EP2, CP1, PP5, VPP5	分层 EP All-to-All 通信 自适应流水掩盖机制 融合算子	相对提升 35%

幅提升训练效率，实现了 MFU 相对提升 35%，如表 2 所示。

为了充分发挥这些优化策略在昇腾 NPU 集群上模型训练的性能提升，盘古 Pro MoE 的模型训练采用了精心调整的并行策略：张量并行 (TP) = 8，专家并行 (EP) = 2，流水线并行 (PP) = 5，虚拟流水线并行 (VPP) = 5，上下文并行 (CP) = 1。TP 和 EP 的大小是为了适配并最优化分层专家并行 All-to-All 通信而设计的。与盘古 Ultra MoE 相比，EP 减小为 2，以便在显存容量允许的情况下最小化 EP 通信量。模型包含 48 个 Transformer 层，为了在流水线阶段实现更好的负载均衡，增加了 2 个无操作 (no-op) 层，使总层数增加到 50。这些层随后被均匀划分为 5 个流水线阶段，并进一步细分为 5 个虚拟流水线阶段。这种 5×5 的 PP-VPP 配置确保了设备之间计算和通信开销的平衡，提高了训练过程的整体可扩展性和吞吐量。由于盘古 Pro MoE 和盘古 Ultra MoE [11] 相比在 PP-VPP 配置上有所减小，因此在训练的预热阶段的总激活显存显著减少。这种较低的显存需求使得盘古 Pro MoE 能够在不依赖盘古 Ultra MoE 所需的显存优化策略（包括细粒度重计算和 swap 方案）的情况下稳定训练。因此，通过消除显存策略带来的额外开销，实现训练效率的进一步提升。此外，由于减少了 EP 通信量以及消除了 token 重排重计算的通信开销，自适应流水掩盖机制中的算子调度完美适配盘古 Pro MoE，最优化通信与计算的掩盖效果。

此外，章节 2.2 提出的分组混合专家 (MoGE) 架构在实际训练过程中降低了 permute 和 gmm_up 算子执行时间在设备间的最大差异值，实测指标验证了其对标标准 MoE 架构中计算不平衡问题的缓解幅度超过 50%。

我们也通过改进架构进一步优化了昇腾训练算子性能。对于矩阵乘等基础算子，我们在数据从通用内存首次传输至 L1 缓存的过程中，基于更小的 L0 缓存容量调整分块大小，使数据能够更早期地从 L1 缓存传输至 L0 缓。最终降低了整体矩阵乘的延迟，并使 cube 算力的使用率提高了超过 10%。同时结合昇腾的架构特性，对缓存策略进一步优化。通过改进矩阵分块的方式以及调整数据搬运顺序，并引入交错分配计算块以规避访问冲突，大幅提高了 HBM 带宽利用率，进而取得算子性能 5% - 10% 的提升。这些系统性优化减少了计算冗余，提高了数据传输效率，并充分挖掘了昇腾硬件性能以提高训练吞吐量。

4.2 针对昇腾 NPU 优化的推理系统

4.2.1 并行优化

分层混合并行 盘古 Pro MoE 采用混合专家模型结构，其中总参数的 95% 为稀疏专家模块，而注意力模块仅占 5%。如图 4 所示，基于模型结构与昇腾硬件系统的联合优化，我们提出了一种分层混合并行 (H²P) 的分布式推理方案，通过消除冗余的计算和通信开销实现最优计算效率。




图 4: 推理系统优化概述。采用 H²P 策略实现不同模块间的高效分布式并行推理。此外，针对昇腾平台专门设计了两个关键融合算子 MulAttention 和 SwiftGMM，以加速模型推理。

在 300I Duo NPU 场景中，每颗 CPU 控制四颗 NPU 芯片。因此，对于注意力模块，我们采用混合的 DP2+TP4 并行策略以减少跨 CPU 通信开销。我们将数据沿 batch 维度分组，以平衡 CPU 之间的计算。对于专家模块，我们采用张量并行（TP）和专家并行（EP）的混合方案，以缓解内存和延迟的问题。EP 通过保留完整的专家参数矩阵来提高计算效率，但是会导致负载不均衡。TP 通过分割专家参数矩阵来实现负载平衡，但可能会因矩阵分割而降低计算效率。基于实际性能分析，我们最终采用 EP4+TP2 的混合并行策略来平衡这些因素。对于共享专家，由于其计算负载均匀，因此采用 TP8 实现密集、高效且均衡的计算。

通信策略 基于优化后的分层混合并行策略，我们进一步对相关通信操作展开优化，以最小化计算和通信开销。对于注意力模块，我们采用 DP2+TP4 并行策略。其中，输入数据被分割为两个 mini-batch，每个 batch 在四个设备上推理。该配置原本需要一次 AllReduce 操作和一次 AllGather 操作。为了优化通信效率，我们将“AllReduce + AllGather”等效替换为“Reduce-Scatter + AllGather”操作，这样使通信数据量减少了 50%。此外，我们将 AllGather 算子转移到 RMSNorm 算子之后，而非之前。这一调整使 RMSNorm 计算能够在跨设备间并行执行，通过分布式处理降低了 75% 的计算负载。在 MOE 模块中，我们采用 EP4+TP2 混合并行策略，其中共享专家通过 TP8 并行处理。全局 AllReduce 操作融合路由专家和共享专家的结果，并获得模块的最终输出。为保持与后续 DP2 注意力模块的兼容性并避免划分数据产生的额外开销，我们将全局 AllReduce 分解为两步，第一步是全局 Reduce-Scatter 操作，第二步在四个设备上执行本地 AllGather 操作。

通信-计算融合 在并行与通信优化的基础上，我们通过相邻通信流与计算流之间的流水掩盖，进

一步降低了通信延迟。多流融合将通信任务与计算任务映射到独立的硬件单元，通过解耦数据依赖关系实现并行执行。在盘古 Pro MoE 模型中，专家组件的全局 AllGather 和 Reduce-Scatter 操作约占网络总延迟的 8%。为解决这一问题，我们提出了一种细粒度、算子级的通算融合策略，将传统的顺序任务分解为交错的子任务。借助昇腾计算平台的多流架构，我们引入了两种融合策略：GMMRS (GroupedMatMul + Reduce-Scatter) 和 AGMM (AllGather + MatMul)。这些策略实现了细粒度的流水掩盖，提升了整体执行效率。

4.2.2 量化压缩

专家感知量化 对 MoE 模型进行量化会因其稀疏且动态的计算模式而带来特殊的问题。首先，MoE 层中的激活异常值呈现出专家特有的分布，这是由于不同的 tokens 会被路由到不同的专家子集。其次，路由的专家选择机制对量化引起的路由分布扰动非常敏感。即使是门控分数的微小偏差，也可能破坏 Top-K 专家分配逻辑，导致模型性能因 tokens 路由错误而下降。第三，专家激活值的稀疏性会引发校准瓶颈：由于低频专家在参数校准过程中数据覆盖不足，导致量化参数估计不准确，从而产生较大的量化误差。

为解决这些问题，我们提出了一种专家感知后训练量化方法。首先采用**专家感知的平滑聚合策略**来抑制 MoE 中各专家的激活离群值。通过构建统一的逐通道平滑向量，该向量聚合了专家层和路由层的最大缩放需求，我们通过与前面归一化层的参数融合保持数学等价性的同时，重新分配离群值的幅度。对于一个具有 d 个通道的 token 向量 $\mathbf{x} \in R^d$ 以及一个包含 n 个本地专家的 MoE 层，我们通过对专家特定和路由特定的要求进行逐通道最大化来实现这一点：

$$\bar{s}_j = \max \left(\underbrace{\max_{i \in [1, n]} \left(\frac{\max(|\mathbf{x}_j|)^\alpha}{\max(|\mathbf{W}_j^i|)^{1-\alpha}} \right)}_{\text{专家要求}}, \underbrace{\frac{\max(|\mathbf{x}_j|)^\alpha}{\max(|\mathbf{W}_j^{\text{gate}}|)^{1-\alpha}}}_{\text{路由要求}} \right), \quad (10)$$

其中下标 j 表示第 j 个输入通道， α 表示迁移强度， $\mathbf{W}^i$ 表示第 i 个本地专家的第一个权重矩阵， $\mathbf{W}^{\text{gate}}$ 表示路由层的权重矩阵。

为确保量化后专家选择的一致性，我们提出了一种**路由输出分布一致性校准策略**，通过最小化路由层 logits 量化前后的重构误差和 KL 散度来对齐路由层 logits 分布。从而保证量化扰动下仍能稳定激活 Top-K 专家，确保量化前后专家选择的一致性。最后，我们提出了一种**专家级校准数据均衡策略**，通过对低频专家做校准数据增量采样，平衡不同专家间的校准数据，消除因校准数据过少导致量化参数估计不准的问题，有效提升低频专家校准量化参数的准确性。

KV 缓存量化和稀疏性 KV 缓存压缩 [13, 14, 15, 16, 17] 对于优化推理基础架构的效率尤其是在吞吐量、上下文长度和 batch size 大小可扩展性方面至关重要。量化和稀疏性技术能够在提升推理效率和整体用户体验的同时，稳定缓解 KV 抢占问题。KVtuner 算法 [16] 通过硬件友好的混合精度量化，实现了推理效率与模型精度之间的优化平衡。这个适配昇腾的框架利用离线分析和多目标优化，为粗粒度 KV 缓存段推导出帕累托最优 (pareto optimal) 的分层量化配置。KVtuner 的自适应性通过解决分层敏感性和动态 token-专家交互，确保了在 MoE 架构中实现有效的 KV 缓存压缩。




图 6: SwiftGMM 总体框架: (a) 分块缓存策略利用历史性能分析来预测动态工作负载下的最优分块参数。(b) 双缓冲区机制将数据传输与计算重叠, 以最大化昇腾 300I Duo 上的 MTE2 利用率。

幅减少冗余内存传输。如图 6 (b) 所示, 我们通过双缓冲机制, 使数据搬运与计算过程重叠, 从而提升 MTE2 流水线利用率。实验表明, SwiftGMM 的 MTE2 利用率最高可达 95%, 使算子性能接近权重数据传输带宽限制的理论上限。

4.2.4 预填充和解码阶段分析

在计算密集的预填充阶段, 对于 MoE 架构, 每个 token 仅激活 8 个专家, 这有效地将模型参数缩减至等效的 16B 稠密模型。这种稀疏激活机制显著降低了计算成本和通信开销。此外, 采用最小 NPU 部署策略可进一步提升预填充阶段的计算效率。与主流的 32B 和 72B 稠密模型相比, 在相同硬件条件下, 盘古 Pro MoE 实现了更低的延迟和更高的输入吞吐量。

在以访存密集型操作为主导的解码阶段, 对于小 batch size (例如 1), 盘古 Pro MoE 可将延迟约束在几十毫秒以内。对于大 batch size (例如 64), 模型通过其稀疏专家激活范式, 协同利用宽度压缩和深度缩减技术, 有效降低了 KV 缓存占用和节点间通信开销, 同时缓解了计算瓶颈。因此, 与同等规模的稠密模型相比, 盘古 Pro MoE 在 100 ms 延迟条件下显著地展现出更高的输出吞吐量。模型推理性能的详细实验如章节 5.3 所示。

5 实验结果

在本章中, 我们首先介绍了盘古 Pro MoE 在各种基准测试中的表现, 并与千亿参数量以下的最先进的模型进行了比较与分析。然后, 我们分析对比了盘古 Pro MoE 与近似参数量的稠密模型在昇腾平台上的推理效率。最后, 我们通过详细分析推理过程中的专家激活模式等来研究盘古 Pro MoE 的 MoGE 的架构中专家的激活特性和专家均衡程度。

5.1 预训练模型

在经过 13T 高质量文本 token 的预训练后，盘古 Pro MoE 显著提升了其语言理解能力与逻辑推理能力。为全面评估该预训练模型在不同任务维度上的表现，我们从中文、英文及推理能力等多个核心领域对盘古 Pro MoE 进行了系统性测评。

5.1.1 评测基准

我们构建了一套覆盖全面的评测体系，用以系统评估模型在中文、英文及推理能力等多个核心任务领域中的表现。为充分展现模型在不同任务类型下的能力，我们选取了具有代表性的一系列权威基准数据集，具体评测指标详见表 3。在中文与英文任务方面，我们采用的评测基准包括：C-Eval [18]、CMMLU [19]、CMRC [20]、C3 [21]、CCPM [22]、CLUEWSC [23]、Big-Bench-Hard [24]、MMLU [25]、MMLU-Pro [26]、DROP [27]、HellaSwag [28]、PIQA [29]、WinoGrande [30]、RACE-Middle 和 RACE-High [31]。在推理能力评估方面，我们采用了 HumanEval [32]、MATH [33]、CMath [34] 以及 GSM8K [35] 等数据集，覆盖代码生成、数学推理等推理任务，旨在衡量模型在高阶认知与复杂推理场景下的表现。

5.1.2 评测结果

如表 3 所示，在众多评估维度中，在与 Qwen2.5-32B（Qwen 系列 32B 参数量下的最新开源模型）、GLM4-32B、Gemma3-27B 和 Llama-4-Scout 等先进预训练模型进行基准测试时，盘古 Pro MoE 都是最具竞争力的模型之一。该模型在包括 MMLU 和 HellaSwag 在内的关键英语基准测试中取得了最优秀性能，同时在大多数中文评估（C-Eval、C3 和 CCPM）中占据领先地位。我们使用 GSM8K 基准对其数学推理能力进行了评估，进一步证实了该模型的逻辑推理能力。

5.2 指令遵从模型

得益于高效的监督微调和强化学习训练，盘古 Pro MoE 展现出了强大的指令跟随能力和复杂的逻辑推理能力。为了全面评价这些能力，我们在一系列具有挑战性的任务上进行了评估。

5.2.1 评测设置

评测基准 我们在中文、英文和推理三个任务领域的多个权威基准上，对盘古 Pro MoE 进行了系统评估。针对中文和英文任务，我们增加了以下测评数据集：MMLU-Redux [36]、IF-Eval [37] 和 Arena-Hard [38]。为进一步评估模型在复杂任务中的推理能力，我们还在以下数据集上进行了测试：LiveCodeBench [39]、MBPP+ [40]、GPQA-Diamond [41]、SuperGPQA [42]、AIME 2024 [43]、AIME 2025 [44]、MATH-500 [45] 和 CNMO 2024¹。

对比基线 我们与其它多种架构并且参数规模相当的业界领先（SOTA）模型进行了对比。参与对比的基准模型包括稠密模型（Qwen3-32B [46]、GLM4-Z1-32B [47]、Gemma3-27B [48]）和 Llama4-

¹<https://www.cms.org.cn/Home/comp/comp/cid/12.html>

表 3: 盘古 Pro MoE 与其他有代表性的基础模型在评估语言和推理能力的各种基准测试中的比较。**粗体**结果代表每行中的最佳结果。

Benchmark (Metric)		# Shots	Qwen2.5 32B Base	GLM4 32B Base	Gemma3 27B Base	Llama-4 Scout Base	Pangu Pro MoE Base
Architecture		-	Dense	Dense	Dense	MoE	MoE
# Activated Params		-	32B	32B	27B	17B	16B
# Total Params		-	32B	32B	27B	109B	72B
English	BBH (EM)	3-shot	82.4	83.3	77.7	79.5	81.2
	MMLU (EM)	5-shot	84.2	82.0	78.6	78.3	87.4
	MMLU-Pro (EM)	5-shot	58.0	55.8	50.3	50.3	63.5
	DROP (F1)	3-shot	79.2	86.2	77.2	77.5	81.1
	HellaSwag (EM)	10-shot	93.1	92.6	84.1	81.9	93.5
	PIQA (EM)	0-shot	90.6	91.8	83.3	88.9	89.3
	WinoGrande (EM)	5-shot	80.7	87.1	71.9	71.4	75.6
	RACE-Middle (EM)	5-shot	95.3	94.0	93.8	92.3	95.8
	RACE-High (EM)	5-shot	93.0	92.4	90.5	88.9	93.9
Chinese	CLUEWSC (EM)	5-shot	88.3	85.7	82.0	83.8	85.0
	C-Eval (EM)	5-shot	87.7	84.1	69.4	74.8	90.6
	CMMLU (EM)	5-shot	88.9	83.8	70.4	76.8	89.0
	CMRC (EM)	1-shot	66.2	76.3	70.8	67.4	79.8
	C3 (EM)	0-shot	96.3	94.5	62.8	94.4	95.4
	CCPM (EM)	0-shot	86.6	87.4	69.9	81.6	90.3
Reasoning	HumanEval (Pass@1)	0-shot	57.9	59.1	48.8	54.6	63.7
	MATH (EM)	4-shot	57.9	46.7	50.0	52.7	55.9
	CMath (EM)	3-shot	83.5	77.5	76.8	83.7	79.7
	GSM8K (EM)	8-shot	83.0	85.4	82.6	79.2	86.5

Scout [49] MoE。对于有提供公开 API 的模型，我们通过其官方接口并采用标准配置进行评测。对于未开放 API 的开源模型，我们在本地部署实例，并在相同评估设置下进行测试。

详细评测配置 为全面评估后训练模型的性能表现，我们构建并采用了标准化的统一评估框架。具体而言，对于 LiveCodeBench、MBPP+ 和 IF-EVAL 数据集，我们严格遵循官方网站提供的评估方法；对于 Arena-Hard 数据集，我们采用裁判打分机制进行评估，以确保结果的公正性与客观性；其余数据集则通过规则匹配和精确匹配等评估策略衡量模型性能。值得一提的是，LiveCodeBench 的评估基于其 24.8.1–25.1.1 版本，该版本涵盖了当前阶段的数据和问题集，具有良好的代表性。

在提示工程方面，我们统一遵循各数据集创建者提供的默认提示格式，以保持评估的一致性和可比性。为确保模型有能力处理大量输入和输出，我们将最大输入长度设为 4K 个 token，最大输出长度设为 28K 个 token。该配置旨在模拟真实应用中对长文本理解与生成的需求，从而全

表 4: 盘古 Pro MoE 与其他有代表性的基础模型在评估语言和推理能力的各种基准测试中的比较。**粗体**结果代表每行中的最佳结果。

Benchmark (Metric)		Qwen3-32B	GLM-Z1-32B	Gemma3-27B	Llama4-Scout	Pangu Pro MoE
Architecture		Dense	Dense	Dense	MoE	MoE
# Activated Params		32B	32B	27B	17B	16B
# Total Params		32B	32B	27B	109B	72B
English	MMLU (EM)	89.2	-	77.6	79.4	89.3
	MMLU-Pro (EM)	78.6	-	67.5	73.8	82.6
	MMLU-Redux (EM)	83.2	88.2	81.7	84.8	81.5
	DROP (F1)	91.3	-	88.4	89.3	91.2
	IF-Eval (Prompt Strict)	84.3	84.5	83.4	85.2	85.7
	Arena-Hard	94.7	90.6	89.8	68.9	93.6
Chinese	CLUEWSC (EM)	94.6	93.6	91.3	87.6	94.7
	C-Eval (EM)	89.2	82.7	65.2	77.3	91.1
	CMMLU (EM)	84.6	-	65.9	70.0	87.1
Reasoning	LiveCodeBench (Pass@1)	62.6	59.1	29.7	33.1	59.6
	MBPP+ (Pass@1)	82.0	75.7	73.8	73.5	80.2
	GPQA-Diamond (Pass@1)	68.2	66.1	42.4	53.5	73.7
	SuperGPQA	49.8	52.6	35.6	45.0	54.8
	AMIE2024 (Pass@1)	80.4	80.8	26.9	29.0	79.2
	AMIE2025 (Pass@1)	70.9	63.6	22.6	10.2	68.1
	MATH-500 (EM)	96.6	94.4	87.8	82.4	96.8
	CNMO2024 (Pass@1)	70.4	71.4	40.7	20.4	70.8

面衡量模型在复杂条件下生成完整响应的能力。

5.2.2 评测结果

英文基准 如表 4 所示，盘古 Pro MoE 在英文推理任务中展现出卓越的性能表现。MMLU-PRO 作为大规模多任务理解基准数据集，其评估维度较经典 MMLU 数据集具有更高的挑战性，能够更精准地评估大语言模型的深层认知能力。实验数据显示，盘古 Pro MoE 在 MMLU-PRO 上以显著优势超越当前主流的稠密模型（包括 Qwen3-32B、GLM-Z1-32B 和 Gemma3-27B）及 MoE 架构的 Llama4-Scout 模型，创下新的性能标杆。在阅读理解领域，盘古 Pro MoE 于 DROP 基准测试中获得 91.2 的优异成绩，与当前最优的 Qwen3-32B 模型（91.3）基本持平，充分验证其具备与前沿模型相当的英文文本理解与推理能力。

中文基准 在中文领域评估中，盘古 Pro MoE 展现出专业化的语言理解优势。具体而言，在知识密集型评测 C-Eval (EM) 中，盘古 Pro MoE 以 91.1 的卓越成绩超越 Qwen3-32B (89.2) 等现有百亿参数量级最优模型。针对中文常识推理任务，盘古 Pro MoE 在 CLUEWSC (EM) 基准上取得 94.7 的高分，较 Qwen3-32B (94.6) 实现微幅提升，并明显领先于 Gemma3-27B (91.3) 等其他对比模型。实验结果表明，盘古 Pro MoE 在中文语义理解与常识推理方面达到行业领先水平。

推理基准 盘古 Pro MoE 在保持高效推理的同时，展现出优异的逻辑推理能力。代码生成方面，在 MBPP+ (Pass@1) 的指标达到 80.2，与 Qwen3-32B (82.0) 处于同一性能区间。数学推理任务中，MATH-500 测试以 96.8 分超越 Qwen3-32B (96.6)，CNMO2024 基准 Pass@1 指标 70.8 亦较后者 (70.4) 提升 0.4 分。特别在 SuperGPQA 复杂问题解答基准中，54.8 的 Pass@1 得分显著优于 GLM-Z1-32B (52.6) 和 Qwen3-32B (49.8) 等稠密模型。值得注意的是，在仅激活 160 亿参数的配置下，盘古 Pro MoE 的推理能力即可媲美 320 亿 (32B) 量级的先进模型。这种高效率源于创新的 MoGE 架构设计，该架构在保证逻辑推理精度的同时，保障了高效的推理速度。

表 5: Ascend 800I A2 上 Prefill 阶段模型推理性能。输入序列长度为 2048，batch size 为 2。TTFT (首 token 时延) 为模型生成第一个 token 的前向推理耗时。吞吐量按每张卡计算。

Model	TTFT (ms)	Input Throughput (tokens/s)
72BA16B MoE	424.21	4828
32B Dense	604.07	3390
72B Dense	1282.94	1596

表 6: Ascend 800I A2 上 Decode 阶段模型推理性能。输入序列长度为 2048。TPOT (每 token 输出时延) 为生成每个 token 的前向推理耗时。吞吐量按每张卡计算。* 代表使用高接受率的 MTP 模块加速以及相关优化。

Model	Batch size	TPOT (ms)	Output Throughput (tokens/s)
72BA16B MoE	1	18.44	14
	456	99.31	1148
	584	95.56	1528*
32B Dense	1	16.26	15
	336	86.34	973
72B Dense	1	26.88	9
	228	97.74	583

5.3 推理效率

模型性能 (基于 Ascend 800I A2) 盘古 Pro MoE (参数配置为 72BA16B) 经过 W8A8 量化配置，在 Ascend 800I A2 上表现出卓越的推理效率。在 Prefill 阶段采取 2 卡部署策略，每轮推理采用 2 路并发批次推理，在 2K 序列长度输入场景下，模型的平均单卡输入吞吐可达 4828 token/s，相比 72B 和 32B 稠密模型分别提升了 203% 和 42%，如表 5 所示。该计算效率优势主要来源于模型激活参数量，与 72B 和 32B 稠密模型相比，盘古 Pro MoE 的单 token 计算参数量仅为两者的 22% 和 50%，因此具有更低的计算负载。

在 Decode 阶段采用 4 卡部署策略，基于 W8A8 量化的性能数据如表 6 所示。在小并发场景

表 7: Ascend 300I Duo 上 Prefill 和 Decode 阶段模型推理性能。输入序列长度为 2048。吞吐量按每张卡计算。* 代表使用高接受率的 MTP 模块加速以及相关优化。

Model	Stage	Batch size	Latency (ms)	Throughput (tokens/s)
72BA16B MoE	Prefill	2	1940.3	1055
	Decode	80	99.5	201
	Decode	128	99.7	321*

表 8: 不同量化位宽下的模型精度损失。

Method	Accuracy loss			
	MATH-500	Live CodeBench	Arena Hard	GPQA Diamond
W8A8	0.80	0.37	0.60	0.51
W4A8	1.20	3.68	3.40	2.53

下，如单批次 2K 序列输入，盘古 Pro MoE 的权重搬运量约为 16B，因此可实现低时延推理。在大并发场景下（满足 Decode 时延 100 ms 约束），在 batch size 为 456 的 2K 序列输入下平均单卡输出吞吐可达 1148 token/s，相较 72B 和 32B 稠密模型吞吐性能分别提升 97% 和 18%。进一步，当采用多 token 预测（Multi Token Prediction, MTP）解码和相关优化时，该模型的输出吞吐量可提升至单卡 1528 tokens/s。

进一步性能分析表明，盘古 Pro MoE 推理时的权重搬运仅占总时延约 29%，其余耗时主要包括 KV 缓存搬运、集合通信和矩阵乘计算。与 72B 和 32B 稠密模型相比，盘古 Pro MoE 采用了更小的隐藏层维度（5120）和模型层数（48）配置，因此其 KV 缓存大小和通信量分别降低了约 40%/25% 和 63%/25%。得益于稀疏激活的计算优势以及模型结构参数的 KV 访存与通信优势，盘古 Pro MoE 具有显著的推理吞吐性能优势。

模型性能（基于 Ascend 300I Duo） 基于盘古 Pro MoE 与昇腾平台的联合设计优化，昇腾 300I Duo 推理服务器可以高效且低成本的实现百亿级 MoE 模型推理部署。盘古 Pro MoE 在推理过程中以 W8A8 配置进行量化。Prefill 阶段采用 2 卡部署实现 2 路并发批次推理，在 2K 输入序列下推理时延为 1.94s，平均单卡输入吞吐达 1055 tokens/s。Decode 阶段采用 4 卡分布式部署方案，在单批次和序列长度为 2K 的低并发场景下实现了约 50 ms 的低延迟推理。在 batch size 为 80 的高并发场景下，平均单卡输出吞吐可达 201 tokens/s（推理时延 99.5 ms），实现高吞吐推理性能，如表 7 所示。进一步，采用 MTP 解码和相关优化的加速，模型的输出吞吐量可提高到 321 tokens/s。在盘古模型和昇腾平台的软硬协同极致性能优化下，盘古 Pro MoE 模型在昇腾 300I Duo 上实现百亿规模大模型推理极致性价比。

模型量化性能 我们在大量基准测试中对量化性能进行了广泛评估。如表 8 所示，在 W8A8 量化配置下，我们的方法几乎实现了无损精度。即便使用 W4A8 量化，精度损失仍在可接受范围内。




图 7: 盘古 Pro MoE 中的专家特化。每个子图展示了特定任务的 token 在特定层中到专家的路由分布情况。条形图代表了分配给单个专家的 token 比例，并根据 token 总数进行了归一化处理。盘古 Pro MoE 每层使用 64 名专家，每个 token 激活 8 名专家，因此每个专家的期望均匀分布为 12.5%-灰色虚线表示。然而，观察到的分布却大大偏离了这一均匀基线，凸显了明显的专家特化程度。这种特化表明了有效的专家分化，有助于提高模型训练和整体性能。

5.4 实验分析

为了更好地理解 MoGE 架构在盘古 Pro MoE 中的有效性，我们系统地研究了 MoE 模型固有的关键特征，如“领域特化”、“专家协同”、“专家组内分布”和“专家全局分布”。

领域特化 专家特化模式是衡量 MoE 层有效性的关键指标，因为它反映了专家从数据中成功学习和内化知识的程度。在本节中，我们将研究一系列任务中的专家特化现象，以了解这种模式在不同条件下的变化情况。我们的分析基于四个不同的数据集：C-Eval，MMLU，GSM8K 和 HumanEval，它们分别对应中文能力、英文能力以及数学和编程方面的高级推理能力。

如图 7 所示，我们分析了三个具有代表性的层：浅层、中层和深层（即第 0 层、第 23 层和第 47 层）的 token 路由到专家的分配情况。在不同的任务中，同一层的 token 会优先路由到不同的专家，从而导致专家特化的存在差异。在浅层（第 0 层），专家表现出高度一致的激活模式。与此相反，深层中的专家表现出越来越高的特化程度：第 47 层的专家比第 23 层的专家表现出更高的特化程度，而第 23 层的专家又超过了第 0 层的专家。这种渐进趋势表明，专家的特化程度随着网络深度的增加而加强。此外，对于主要评估通用语言理解能力的任务，如 C-Eval 和 MMLU，专家激活的分布在整个专家集中趋于平衡。相比之下，在推理密集型任务（如 GSM8K 和 HumanEval）中，专家激活表现出更高的特化程度，表明路由行为更具选择性和任务特定性。

我们对专家特化的分析表明，盘古 Pro MoE 表现出了针对不同任务的实质性专家分化差异，这增强了模型的表征能力，并有助于提高其整体性能。




图 8: 在 C4 验证集的 0.5% 随机采样子集上评估了三个层（浅层、中层和深层）的专家协同激活情况。图中显示的是前四个专家组，每个专家组包含前四名专家，其专家 ID 位于 x 轴和 y 轴上。颜色强度反映了专家对之间的协同激活得分。

专家协同 为了分析专家之间的协同行为，我们构建协同激活矩阵以可视化专家间的共激活情况，矩阵中的每个单元格代表一对专家对同一输入 **token** 同时被激活的概率。协同激活得分越高，说明相应专家对输入的响应越一致，反映出更强的路由决策相关性和更显著的协同作用。

为全面反映网络结构中不同深度的协同特性，我们从模型的浅层、中层和深层中分别选取三个具有代表性的层进行分析。如图 8 所示，协同激活矩阵对角线上的空白区域表明，同组专家之间不存在共同激活的情况。这种稀疏结构源于我们引入的分组路由机制。

此外，我们发现来自不同组的专家在各层中的协同激活得分始终处于较低水平，最大值仅为 20%，表明组间交互极为有限。这一结果验证了我们的设计初衷，即我们的模型实现了较低程度的专家冗余，并鼓励特化，即不同组的专家负责不同方面的表征学习。

值得注意的是，各层之间的协同激活模式呈现出非单调的变化趋势：浅层和深层的协同激活得分略高于中间层。一种可能的解释是，在早期特征提取阶段（学习通用模式）和晚期整合阶段（将不同信号结合起来进行复杂的任务预测），模型受益于更广泛的专家协作。相比之下，中间层可能专注于更局部化的表示学习，因此表现出更强的专家特化倾向和更低的协同激活程度。




图 9: 盘古 Pro MoE 中的组内专家路由分布。观察到的 **token** 分布与这一理论基线非常接近，表明盘古 Pro MoE 有效地保持了每个组内专家的均衡使用。这种均衡的激活有助于防止专家使用不足或过度饱和，从而促进稳定的训练动态并最大化专家组的集体能力。

专家组内分布 盘古 Pro MoE 通过在每个专家组内强制仅激活一名专家，从机制上促进了组间专家的负载均衡性。为进一步探究该均衡性是否在组内也得以维持，我们对组内专家的负载分布




图 10: 第一层的全局专家路由分布情况，使用 C4 验证集的 0.5 % 随机采样子集进行评估。盘古 Pro MoE 对专家的使用更为均衡，每个专家的 token 比例更接近理想的 12.5%。

进行了系统分析。如图 9 所示，我们对前四组专家在三个具有代表性的层（浅层、中层与深层）中的 token 分配比例进行了可视化。从整体趋势来看，token 在同组内的专家之间分配较为均匀，单个专家平均获得约 12.5% 的 token 这与 8 位专家组成的组在 Top-1 激活下的理论平均值一致。这一观察结果进一步证明，MoGE 架构不仅能够天然的确确保组间负载平衡，还能促进组内负载平衡，使其有利于专家的均衡使用。

值得注意的是，在更深层的网络中，我们观察到组内负载均衡性出现轻微偏离，token 分配呈现出一定程度的倾斜性。这一趋势与我们在图 7 中所展示的深层专家路由日益专业化的现象相一致，这表明模型在深层阶段可能会对专家的激活进行适应性调节，以更有效地捕捉任务特定或更高层次的抽象语义表示。

专家全局分布 在 MoE 架构中，专家负载的均衡性始终是一个关键问题，因为更均匀的专家激活不仅有助于提升计算资源的利用效率，还能带来更稳定的训练动态与更强的模型泛化能力。为深入分析该问题，我们对模型中专家负载的分布特性进行了系统分析，并将盘古 Pro MoE 与业界广泛认可的开源 MoE 模型 DeepSeek-V2 进行了对比评估。

如图 10 所示，DeepSeek-V2 在专家负载分布上存在明显的不均衡现象，其中负载最高的专家承担了约 30% 的 token，整体分布的波动较大。相较之下，盘古 Pro MoE 展现出更加理想的专家激活模式，各专家的 token 处理比例高度接近均值，每位专家平均处理约 12.5% 的 token，几乎与理论上的均匀分布一致（即每组激活 8 个专家中的任意一个，其期望占比为 $8/64 = 12.5\%$ ）。

这一均衡的激活模式反映出盘古 Pro MoE 所采用的路由机制在专家利用率方面具有显著优势，能够充分调动专家计算能力，有效缓解负载集中带来的资源瓶颈问题。更进一步，负载分配的合理性不仅有助于降低个别专家过载的风险，还能避免训练过程中的性能瓶颈与计算资源的浪费，从而在保证效率的同时增强模型的稳定性与可扩展性。

6 结论

本文推出了基于 MoGE 架构的混合专家模型盘古 Pro MoE，这一具有 720 亿总参数量的 MoE 模型有效解决了分布式部署 MoE 模型时的跨设备专家负载不均衡问题。盘古 Pro MoE 通过在预定义的分组内对专家选择进行约束，保持了 MoE 模型参数效率的同时（每个 token 激活 160 亿参数），也天然的实现了跨设备的负载均衡。通过盘古模型与昇腾平台的软硬协同优化，盘古 Pro MoE 在 800I A2 实现了大并发高吞吐推理，并在 300I Duo 实现了极致推理性价比。多项公开基准测试结果表明，盘古 Pro MoE 在千亿内总参数模型中处于领先地位。这些突破使盘古 Pro MoE 成为部署大规模 MoE 模型的实用解决方案。本研究充分印证了模型架构与目标硬件平台协同设计的核心价值。

参考文献

- [1] N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, and J. Dean, “Outrageously large neural networks: The sparsely-gated mixture-of-experts layer,” arXiv preprint arXiv:1701.06538, 2017.
- [2] W. Cai, J. Jiang, F. Wang, J. Tang, S. Kim, and J. Huang, “A survey on mixture of experts,” arXiv preprint arXiv:2407.06204, 2024.
- [3] A. Q. Jiang, A. Sablayrolles, A. Roux, A. Mensch, B. Savary, C. Bamford, D. S. Chaplot, D. d. l. Casas, E. B. Hanna, F. Bressand et al., “Mixtral of experts,” arXiv preprint arXiv:2401.04088, 2024.
- [4] N. Du, Y. Huang, A. M. Dai, S. Tong, D. Lepikhin, Y. Xu, M. Krikun, Y. Zhou, A. W. Yu, O. Firat et al., “Glam: Efficient scaling of language models with mixture-of-experts,” in International Conference on Machine Learning. PMLR, 2022, pp. 5547–5569.
- [5] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar et al., “Llama: Open and efficient foundation language models,” arXiv preprint arXiv:2302.13971, 2023.
- [6] Y. Wang, H. Chen, Y. Tang, T. Guo, K. Han, Y. Nie, X. Wang, H. Hu, Z. Bai, Y. Wang et al., “Pangu- π : Enhancing language model architectures via nonlinearity compensation,” arXiv preprint arXiv:2312.17276, 2023.
- [7] A. Liu, B. Feng, B. Wang, B. Wang, B. Liu, C. Zhao, C. Dengr, C. Ruan, D. Dai, D. Guo et al., “Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model,” arXiv preprint arXiv:2405.04434, 2024.
- [8] Y. Yin, W. Huang, K. Song, Y. Tang, X.-F. Wu, W. Guo, P. Guo, Y. Wang, X. Meng, Y. Wang, D. Li, C. Chen, D. Tu, Y. Li, F. Yu, R. Tang, Y. Wang, B. Wang, B. Wang, B. Wang, B. Liu, C. Zhang, D. Tang, F. Mi, H. Jin, J. Wei, J. Qin, J. Li, J. Zhao, L. Deng, L. Li, M. Xu, N. Zhang, N. Zheng, Q. Li, R. Ruan, S. Cheng, T. Guo, W. He, W. Li, W.-W. Liu, W.-P. Liu, X. Dai, Y. Dong, Y. Pan, Y. Li, Y. Wang, Y. Li, Y. Ni, Z. Liu, Z. Zhang, and Z. Liu, “Pangu ultra: Pushing the limits of dense large language models on ascend npus,” 2025. [Online]. Available: <https://api.semanticscholar.org/CorpusID:277667268>
- [9] D. Lepikhin, H. Lee, Y. Xu, D. Chen, O. Firat, Y. Huang, M. Krikun, N. Shazeer, and Z. Chen, “{GS}hard: Scaling giant models with conditional computation and automatic sharding,” in International Conference on Learning Representations, 2021. [Online]. Available: <https://openreview.net/forum?id=qrwe7XHTmYb>
- [10] A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Li, D. Liu, F. Huang, H. Wei et al., “Qwen2. 5 technical report,” arXiv preprint arXiv:2412.15115, 2024.

- [11] Y. Tang, Y. Yin, Y. Wang, H. Zhou, Y. Pan, W. Guo, Z. Zhang, M. Rang, F. Liu, N. Zhang, B. Li, Y. Dong, X. Meng, Y. Wang, D. Li, Y. Li, D. Tu, C. Chen, Y. Yan, F. Yu, R. Tang, Y. Wang, B. Huang, B. Wang, B. Liu, C. Zhang, D. Kuang, F. Liu, G. Huang, J. Wei, J. Qin, J. Ran, J. Li, J. Zhao, L. Dai, L. Li, L. Deng, P. Qin, P. Zeng, Q. Gu, S. Tang, S. Cheng, T. Gao, T. Yu, T. Li, T. Bi, W. He, W. Mao, W. Huang, W. Liu, X. Li, X. Yu, X. Wu, X. He, Y. Du, Y. Xu, Y. Tian, Y. Wu, Y. Huang, Y. Tian, Y. Zhu, Y. Li, Y. Wang, Y. Gai, Y. Li, Y. Luo, Y. Ni, Y. Sun, Z. Chen, Z. Liu, Z. Liu, Z. Tu, Z. Ding, and Z. Zhan, “Pangu ultra moe: How to train your big moe on ascend npus,” 2025. [Online]. Available: <https://arxiv.org/abs/2505.04519>
- [12] M. Yin, C. Wu, Y. Wang, H. Wang, W. Guo, Y. Wang, Y. Liu, R. Tang, D. Lian, and E. Chen, “Entropy law: The story behind data compression and llm performance,” arXiv preprint arXiv:2407.06645, 2024.
- [13] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, “Efficient streaming language models with attention sinks,” arXiv preprint arXiv:2309.17453, 2023.
- [14] S. Ge, Y. Zhang, L. Liu, M. Zhang, J. Han, and J. Gao, “Model tells you what to discard: Adaptive kv cache compression for llms,” arXiv preprint arXiv:2310.01801, 2023.
- [15] Z. Liu, J. Yuan, H. Jin, S. Zhong, Z. Xu, V. Braverman, B. Chen, and X. Hu, “Kivi: A tuning-free asymmetric 2bit quantization for kv cache,” arXiv preprint arXiv:2402.02750, 2024.
- [16] X. Li, Z. Xing, Y. Li, L. Qu, H.-L. Zhen, W. Liu, Y. Yao, S. J. Pan, and M. Yuan, “Kvtuner: Sensitivity-aware layer-wise mixed precision kv cache quantization for efficient and nearly lossless llm inference,” 2025. [Online]. Available: <https://arxiv.org/abs/2502.04420>
- [17] Q. Yang, J. Wang, X. Li, Z. Wang, C. Chen, L. Chen, X. Yu, W. Liu, J. Hao, M. Yuan et al., “Attentionpredictor: Temporal pattern matters for efficient llm inference,” arXiv preprint arXiv:2502.04077, 2025.
- [18] Y. Huang, Y. Bai, Z. Zhu, J. Zhang, J. Zhang, T. Su, J. Liu, C. Lv, Y. Zhang, J. Lei, F. Qi, Y. Fu, M. Sun, and J. He, “C-eval: A multi-level multi-discipline chinese evaluation suite for foundation models,” ArXiv, vol. abs/2305.08322, 2023. [Online]. Available: <https://api.semanticscholar.org/CorpusID:258685666>
- [19] H. Li, Y. Zhang, F. Koto, Y. Yang, H. Zhao, Y. Gong, N. Duan, and T. Baldwin, “Cmmlu: Measuring massive multitask language understanding in chinese,” arXiv preprint arXiv:2306.09212, 2023.
- [20] Y. Cui, T. Liu, W. Che, L. Xiao, Z. Chen, W. Ma, S. Wang, and G. Hu, “A span-extraction dataset for Chinese machine reading comprehension,” in Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), K. Inui, J. Jiang, V. Ng, and X. Wan, Eds. Hong Kong, China: Association for Computational Linguistics, Nov. 2019, pp. 5883–5889. [Online]. Available: <https://aclanthology.org/D19-1600>

- [21] K. Sun, D. Yu, D. Yu, and C. Cardie, “Investigating prior knowledge for challenging chinese machine reading comprehension,” 2019.
- [22] W. Li, F. Qi, M. Sun, X. Yi, and J. Zhang, “Ccpm: A chinese classical poetry matching dataset,” 2021.
- [23] L. Xu, H. Hu, X. Zhang, L. Li, C. Cao, Y. Li, Y. Xu, K. Sun, D. Yu, C. Yu et al., “Clue: A chinese language understanding evaluation benchmark,” arXiv preprint arXiv:2004.05986, 2020.
- [24] M. Suzgun, N. Scales, N. Scharli, S. Gehrmann, Y. Tay, H. W. Chung, A. Chowdhery, Q. V. Le, E. H. Chi, D. Zhou, and J. Wei, “Challenging big-bench tasks and whether chain-of-thought can solve them,” in Annual Meeting of the Association for Computational Linguistics, 2022. [Online]. Available: <https://api.semanticscholar.org/CorpusID:252917648>
- [25] D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt, “Measuring massive multitask language understanding,” arXiv preprint arXiv:2009.03300, 2020.
- [26] Y. Wang, X. Ma, G. Zhang, Y. Ni, A. Chandra, S. Guo, W. Ren, A. Arulraj, X. He, Z. Jiang et al., “Mmlu-pro: A more robust and challenging multi-task language understanding benchmark,” in The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track, 2024.
- [27] D. Dua, Y. Wang, P. Dasigi, G. Stanovsky, S. Singh, and M. Gardner, “Drop: A reading comprehension benchmark requiring discrete reasoning over paragraphs,” in North American Chapter of the Association for Computational Linguistics, 2019. [Online]. Available: <https://api.semanticscholar.org/CorpusID:67855846>
- [28] R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, and Y. Choi, “Hellaswag: Can a machine really finish your sentence?” in Annual Meeting of the Association for Computational Linguistics, 2019. [Online]. Available: <https://api.semanticscholar.org/CorpusID:159041722>
- [29] Y. Bisk, R. Zellers, R. L. Bras, J. Gao, and Y. Choi, “Piqa: Reasoning about physical commonsense in natural language,” in AAAI Conference on Artificial Intelligence, 2019. [Online]. Available: <https://api.semanticscholar.org/CorpusID:208290939>
- [30] K. Sakaguchi, R. L. Bras, C. Bhagavatula, and Y. Choi, “Winogrande: An adversarial winograd schema challenge at scale,” 2019.
- [31] G. Lai, Q. Xie, H. Liu, Y. Yang, and E. H. Hovy, “Race: Large-scale reading comprehension dataset from examinations,” ArXiv, vol. abs/1704.04683, 2017. [Online]. Available: <https://api.semanticscholar.org/CorpusID:6826032>
- [32] M. Chen, J. Tworek, H. Jun, Q. Yuan, H. Pondé, J. Kaplan, H. Edwards, Y. Burda, N. Joseph, G. Brockman, A. Ray, R. Puri, G. Krueger, M. Petrov, H. Khlaaf, G. Sastry, P. Mishkin,

- B. Chan, S. Gray, N. Ryder, M. Pavlov, A. Power, L. Kaiser, M. Bavarian, C. Winter, P. Tillet, F. P. Such, D. W. Cummings, M. Plappert, F. Chantzis, E. Barnes, A. Herbert-Voss, W. H. Guss, A. Nichol, I. Babuschkin, S. Balaji, S. Jain, A. Carr, J. Leike, J. Achiam, V. Misra, E. Morikawa, A. Radford, M. M. Knight, M. Brundage, M. Murati, K. Mayer, P. Welinder, B. McGrew, D. Amodei, S. McCandlish, I. Sutskever, and W. Zaremba, “Evaluating large language models trained on code,” ArXiv, vol. abs/2107.03374, 2021. [Online]. Available: <https://api.semanticscholar.org/CorpusID:235755472>
- [33] D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt, “Measuring mathematical problem solving with the math dataset,” arXiv preprint arXiv:2103.03874, 2021.
- [34] T. Wei, J. Luan, W. Liu, S. Dong, and B. Wang, “Cmath: Can your language model pass chinese elementary school math test?” 2023.
- [35] K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano et al., “Training verifiers to solve math word problems,” arXiv preprint arXiv:2110.14168, 2021.
- [36] A. P. Gema, J. O. J. Leang, G. Hong, A. Devoto, A. C. M. Mancino, R. Saxena, X. He, Y. Zhao, X. Du, M. R. G. Madani et al., “Are we done with mmlu?” arXiv preprint arXiv:2406.04127, 2024.
- [37] J. Zhou, T. Lu, S. Mishra, S. Brahma, S. Basu, Y. Luan, D. Zhou, and L. Hou, “Instruction-following evaluation for large language models,” arXiv preprint arXiv:2311.07911, 2023.
- [38] T. Li, W.-L. Chiang, E. Frick, L. Dunlap, B. Zhu, J. E. Gonzalez, and I. Stoica, “From live data to high-quality benchmarks: The arena-hard pipeline,” April 2024. [Online]. Available: <https://lmsys.org/blog/2024-04-19-arena-hard/>
- [39] N. Jain, K. Han, A. Gu, W.-D. Li, F. Yan, T. Zhang, S. Wang, A. Solar-Lezama, K. Sen, and I. Stoica, “Livecodebench: Holistic and contamination free evaluation of large language models for code,” arXiv preprint arXiv:2403.07974, 2024.
- [40] J. Austin, A. Odena, M. Nye, M. Bosma, H. Michalewski, D. Dohan, E. Jiang, C. J. Cai, M. Terry, Q. V. Le, and C. Sutton, “Program synthesis with large language models,” ArXiv, vol. abs/2108.07732, 2021. [Online]. Available: <https://api.semanticscholar.org/CorpusID:237142385>
- [41] D. Rein, B. L. Hou, A. C. Stickland, J. Petty, R. Y. Pang, J. Dirani, J. Michael, and S. R. Bowman, “Gpqa: A graduate-level google-proof q&a benchmark,” in First Conference on Language Modeling, 2024.
- [42] M.-A.-P. Team, X. Du, Y. Yao, K. Ma, B. Wang, T. Zheng, K. Zhu, M. Liu, Y. Liang, X. Jin, Z. Wei, C. Zheng, K. Deng, S. Guo, S. Jia, S. Jiang, Y. Liao, R. Li, Q. Li, S. Li, Y. Li, Y. Li, D. Ma, Y. Ni, H. Que, Q. Wang, Z. Wen, S. Wu, T. Xing, M. Xu, Z. Yang, Z. M. Wang, J. Zhou, Y. Bai,

- X. Bu, C. Cai, L. Chen, Y. Chen, C. Cheng, T. Cheng, K. Ding, S. Huang, Y. Huang, Y. Li, Y. Li, Z. Li, T. Liang, C. Lin, H. Lin, Y. Ma, Z. Peng, Z. Peng, Q. Qi, S. Qiu, X. Qu, Y. Tan, Z. Wang, C. Wang, H. Wang, Y. Wang, Y. Wang, J. Xu, K. Yang, R. Yuan, Y. Yue, T. Zhan, C. Zhang, J. Zhang, X. Zhang, X. Zhang, Y. Zhang, Y. Zhao, X. Zheng, C. Zhong, Y. Gao, Z. Li, D. Liu, Q. Liu, T. Liu, S. Ni, J. Peng, Y. Qin, W. Su, G. Wang, S. Wang, J. Yang, M. Yang, M. Cao, X. Yue, Z. Zhang, W. Zhou, J. Liu, Q. Lin, W. Huang, and G. Zhang, “Supergpqa: Scaling llm evaluation across 285 graduate disciplines,” 2025. [Online]. Available: <https://arxiv.org/abs/2502.14739>
- [43] MAA, “Codeforces,” American Invitational Mathematics Examination - AIME 2024, 2024, <https://maa.org/math-competitions/american-invitational-mathematics-examination-aime>.
- [44] —, “Codeforces,” American Invitational Mathematics Examination - AIME 2025, 2025, <https://maa.org/math-competitions/american-invitational-mathematics-examination-aime>.
- [45] H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, and K. Cobbe, “Let’s verify step by step,” arXiv preprint arXiv:2305.20050, 2023.
- [46] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv et al., “Qwen3 technical report,” arXiv preprint arXiv:2505.09388, 2025.
- [47] T. GLM, A. Zeng, B. Xu, B. Wang, C. Zhang, D. Yin, D. Rojas, G. Feng, H. Zhao, H. Lai, H. Yu, H. Wang, J. Sun, J. Zhang, J. Cheng, J. Gui, J. Tang, J. Zhang, J. Li, L. Zhao, L. Wu, L. Zhong, M. Liu, M. Huang, P. Zhang, Q. Zheng, R. Lu, S. Duan, S. Zhang, S. Cao, S. Yang, W. L. Tam, W. Zhao, X. Liu, X. Xia, X. Zhang, X. Gu, X. Lv, X. Liu, X. Liu, X. Yang, X. Song, X. Zhang, Y. An, Y. Xu, Y. Niu, Y. Yang, Y. Li, Y. Bai, Y. Dong, Z. Qi, Z. Wang, Z. Yang, Z. Du, Z. Hou, and Z. Wang, “Chatglm: A family of large language models from glm-130b to glm-4 all tools,” 2024.
- [48] G. Team, A. Kamath, J. Ferret, S. Pathak, N. Vieillard, R. Merhej, S. Perrin, T. Matejovicova, A. Ramé, M. Rivière et al., “Gemma 3 technical report,” arXiv preprint arXiv:2503.19786, 2025.
- [49] M. AI, “The llama 4 herd: The beginning of a new era of natively multimodal ai innovation,” <https://ai.meta.com/blog/llama-4-multimodal-intelligence/>, 2025, accessed: 2025-04-05.

A 贡献和致谢

核心贡献者

唐业辉, 李小松, 刘方程, 郭巍, 周航, 王耀园, 韩凯, 于献智, 李金鹏, 臧慧, 糜飞, 孟笑君, 刘治成, 陈汉亭, 郑斌帆, 陈灿, 颜友亮, 唐睿明, 秦佩峰, 陈醒濠, 陶大程, 王云鹤

贡献者

尹伊淳, 邓利群, 开昆雄, 王宝军, 王哲, 王滨, 王雅圣, 王耀, 包晗, 付中前, 白帆, 白哲源, 田野, 让苗, 任逸贤, 孙宇轩, 刘文杰, 刘鑫铎, 吕涛, 朱冲, 李轩, 李钊, 李祖明, 李冰寒, 李栋, 李敬雍, 杜凡义, 肖安, 陈恭, 宋凯凯, 张子阳, 何为, 余铁峥, 和煦, 林焕, 林东颖, 林焕鑫, 林炜哲, 郑念祖, 胡杰, 胡逸函, 项晨煊, 徐明辉, 夏鹏飞, 倪运升, 郭天宇, 黄兴, 黄永兵, 雷静, 甄慧玲, 詹宗沅, 雍定钰, 路祥, 潘银飞, 魏建生, Fisher Yu

B 案例研究

为了进一步展示盘古 Pro MoE 的综合能力，我们呈现了一系列案例研究，涵盖了需要复杂推理的任务（如数学和逻辑推理）以及非推理类任务（如指令遵从、通用问答和 AI 生成内容 (AIGC)）。这些示例突出了我们模型在高级推理、知识整合以及生成质量方面的优势。我们已用红色字体标记出展示模型回答优势的关键片段。

表 9: 这个例子要求基于输入文本生成不超过 20 个字的摘要。Qwen3-32B 生成的摘要缺乏细节，而盘古 Pro MoE 在字数限制内保留了更多关键信息。

Question: 红藕香残玉簟秋。轻解罗裳，独上兰舟。云中谁寄锦书来？雁字回时，月满西楼。花自飘零水自流。一种相思，两处闲愁。此情无计可消除，才下眉头，却上心头。生成 20 字内摘要

Qwen3-32B (thinking mode): <think> 好的，我现在需要处理用户的一个请求，他们提供了一首李清照的《一剪梅》，然后要求生成一个 20 字以内的摘要。首先，我得仔细分析这首词的内容和主题。

首先，这首词的上片写的是秋天的景象，红藕香残，玉簟秋，营造出一种凄凉的氛围。接着是“轻解罗裳，独上兰舟”，这里可能表达的是主人公独自泛舟的情景，带有孤独感。然后是“云中谁寄锦书来？雁字回时，月满西楼。”这里用了鸿雁传书的典故，表达对远方亲人的思念，等待书信的心情。

下片“花自飘零水自流”继续用自然景象来比喻时光流逝和无法挽回的离别。“一种相思，两处闲愁”点明了主题，两人分隔两地，共同思念。最后两句“此情无计可消除，才下眉头，却上心头。”强调了相思之苦无法排解，从眉头到心头，情感的深沉。接下来，我需要将这些元素浓缩成 20 字以内。要注意关键词：相思、离别、秋景、孤寂、无计可消除。可能需要用简练的词语组合，比如“秋景孤寂，相思难解”或者“离愁别绪，相思缠绵”。但需要确保不超过 20 字，并且涵盖主要情感和意象。

可能的组合有：“秋景孤寂，相思难消”或者“离愁相思，秋水共长天”。不过要检查字数。例如，“秋景孤寂，相思难解”正好 8 个字，可能不够。需要更全面。或者“李清照《一剪梅》以秋景抒写离愁，相思难解。”但可能超过 20 字。需要更精炼。

再想，原词中的“红藕香残”、“兰舟”、“锦书”、“雁字”、“月满西楼”这些意象，但摘要可能不需要具体意象，而是情感和主题。所以重点在“相思”、“离别”、“秋景”、“愁绪”。

最终可能的摘要：“秋景孤寂，相思难解”或者“离愁别绪，相思缠绵”。但可能需要更准确。例如，“秋景孤寂，相思无解”或者“离愁别绪，相思难消”。检查字数，“秋景孤寂，相思无解”是 8 个字，可能太简略。或者“秋景孤寂，相思难消愁”9 个字。或者“李清照《一剪梅》抒写秋日相思离愁。”这样是 13 个字，符合要求。或者“秋日相思，离愁难解”8 个字，但可能不够全面。需要再调整。

可能最佳的是：“秋景孤寂，相思难解”或者“离愁别绪，相思缠绵”。或者结合季节和情感：“秋日相思，离愁难消”。这样是 8 个字，符合 20 字内。或者更准确点：“秋景孤寂，相思无解”或者“秋日相思，离愁难消”。可能后者更好，因为包含了季节和情感，同时“离愁”对应“两处闲愁”，而“难消”对应“无计可消除”。所以最终摘要可以是“秋日相思，离愁难消”正好 8 个字，或者扩展一点：“秋景孤寂，相思难消”也是 8 个字。或者“秋日离愁，相思难解”同样 8 个字。需要确保准确传达原词的意境和情感，同时符合字数限制。</think>

秋日相思，离愁难消

盘古 Pro MoE : <think> 好的，用户让我给李清照的《一剪梅·红藕香残玉簟秋》生成一个 20 字以内的摘要。首先，我需要回顾这首词的内容和主题。

这首词是李清照早期的作品，主要表达了她对远方丈夫的思念之情。开头“红藕香残玉簟秋”描绘了秋天的凄凉景象，接着“轻解罗裳，独上兰舟”表现出她独自泛舟的孤独。然后“云中谁寄锦书来？”直接点出对书信的期盼，“雁字回时，月满西楼”进一步渲染了思念的氛围。下阕“花自飘零水自流”用自然景象比喻离别，“一种相思，两处闲愁”说明双方的思念，最后“此情无计可消除，才下眉头，却上心头”强调了情感的无法排遣。

接下来，我需要将这些内容浓缩到 20 字以内。关键点包括：秋日景象、独处思念、无法消除的相思。要抓住核心情感，即深切的思念和无法排遣的愁绪。可能要用简洁的词汇组合，比如“秋思”、“独愁”、“相思难消”等。还要注意押韵和节奏，但摘要可能不需要严格押韵，只要准确传达情感即可。

尝试几个版本：“秋日独愁，相思难消，此情无计可消除。”但稍长。再简化：“秋思独愁，相思难消，愁上心头。”还是稍长。可能需要更精炼，比如“秋日独愁，相思难消，此情无计。”但可能不够完整。或者“秋景凄凉，独上兰舟，相思难消，愁满心头。”还是字数太多。再调整，去掉具体动作，突出情感：“秋思独愁，两处闲愁，此情难消。”或者更准确点：“秋日独上兰舟，相思难消，愁满心头。”但可能超过。需要更精准，可能用“秋思独愁，两处闲愁，此情难消。”这样符合要求，涵盖了季节、孤独、双方的思念和无法消除的愁绪。</think>

秋思独上兰舟，相思难消，愁满心头。

表 10: 这是一个数学的例子，问题中有一个关键难点：符号 “-(35%)” 的歧义写法。盘古 Pro MoE 能正确处理这一写法。

Question: $28.97-(35\%)-82 \times 40-58.87=?$ Qwen3-32B (thinking mode): <think> Okay, let's see. I need to solve this math problem: 28.97 minus 35%, then minus 82 times 40, then minus 58.87. Hmm, first, I need to figure out what each part means. Let me break it down step by step. Starting with 28.97 minus 35%. Wait, when they say 35%, do they mean 35% of 28.97? Or is it 35% of something else? I think in problems like this, when you see a percentage after a number without a specific context, it's usually a percentage of that number. So 35% of 28.97. Let me confirm that. If I take 35% of 28.97, that would be 0.35 multiplied by 28.97. Let me calculate that. First, 0.35 times 28.97. Let me do 0.35 times 28.97. Maybe I can break it down. 0.35 is the same as 35/100 or 7/20. Alternatively, maybe easier to multiply 28.97 by 0.35 directly. Let me try that. ... Alternatively, if we keep all decimals until the end and then round, we have -3320.0395, which rounds to -3320.04. Therefore, either way, the answer is -3320.04 when rounded to two decimal places. Therefore, the final answer is -3320.04. </think> To solve the expression: $28.97 - (35\%) - 82 \times 40 - 58.87$ we will proceed step by step, interpreting the percentage as 35% of the preceding number (a common convention in many calculators and practical contexts). Step 1: Calculate 35% of 28.97: $35\% \text{ of } 28.97 = 0.35 \times 28.97 = 10.1395$... Step 3: Subtract 58.87: $-3261.1695 - 58.87 = -3320.0395$ Final Step: Rounding: The original numbers (28.97 and 58.87) are given to two decimal places, and the final result is expected to be in a similar format. Rounding -3320.0395 to two decimal places: $-3320.0395 \approx -3320.04$ Final Answer: -3320.04	盘古 Pro MoE : <think> Okay, let's tackle this problem step by step. The expression is 28.97 minus 35% minus 82 times 40 minus 58.87. Hmm, order of operations is crucial here. Remembering PEMDAS—Parentheses, Exponents, Multiplication and Division, Addition and Subtraction. So first, I need to handle the percentage and the multiplication before dealing with the subtractions. Starting with the original expression: $28.97 - 35\% - 82 \times 40 - 58.87$. Let's break it down term by term. The percentage sign can be a bit confusing. Is the 35% referring to 35% of the previous number, which is 28.97, or is it 35% of the entire expression? The way it's written, without parentheses, I think it's just 35% as a standalone value. But percentages can be tricky. Usually, if it's written like this, 35% would be equivalent to 0.35 in decimal form. So maybe I need to convert that percentage to a decimal first. So converting 35% to decimal is 0.35. Now, does that mean we subtract 0.35 from 28.97? Let me check. If the problem was $28.97 - 35\%$, then yes, it's 28.97 minus 0.35. But sometimes, in certain contexts, people might interpret 35% of 28.97, which would be 0.35×28.97. But since there's no parentheses indicating that, I think the correct interpretation is just subtracting 0.35. ... Finally, subtract 58.87 from -3251.38. That's like adding the two negatives. So $-3251.38 - 58.87 = -(3251.38 + 58.87)$. Let's add those two numbers. $3251.38 + 58.87$. Adding the whole numbers: $3251 + 58 = 3309$. Then the decimals: $0.38 + 0.87 = 1.25$. So total is $3309 + 1.25 = 3310.25$. Therefore, the result is -3310.25. Wait, but let me double-check the steps to make sure I didn't make a mistake. Starting with $28.97 - 0.35 = 28.62$. Then $28.62 - 3280 = -3251.38$. Then $-3251.38 - 58.87 = -3310.25$. That seems right. Let me verify the addition again: $3251.38 + 58.87$. $3251 + 58$ is 3309, $0.38 + 0.87$ is 1.25, so $3309 + 1.25$ is indeed 3310.25. So the final result is -3310.25. ... Then subtract 3280: $-30.25 - 3280 = -3310.25$ Yes, same result. So that seems consistent. Therefore, I believe the correct answer is -3310.25. **Final Answer** The result of the expression is -3310.25. </think> To solve the expression $28.97 - 35\% - 82 \times 40 - 58.87$, we follow these steps: 1. Convert the percentage to a decimal: $35\% = 0.35$ 2. Perform the multiplication: $82 \times 40 = 3280$ 3. Substitute the converted percentage and multiplication result back into the expression: $28.97 - 0.35 - 3280 - 58.87$ 4. Perform the subtractions from left to right: - Subtract 0.35 from 28.97: $28.97 - 0.35 = 28.62$ - Subtract 3280 from 28.62: $28.62 - 3280 = -3251.38$ - Subtract 58.87 from -3251.38: $-3251.38 - 58.87 = -3310.25$ Thus, the result of the expression is -3310.25.
---	---

表 11: 这是一个逻辑推理的例子。在处理抽象且复杂的问题时，盘古 Pro MoE 采用多种策略来验证和完善其推理，最终得出正确的解答。

Question: 如果昨天是明天就好了，那么今天就是周五了，请问今天周几？ Qwen3-32B (thinking mode): <think> 嗯，这个问题看起来有点绕，不过让我慢慢来想。题目是说：“如果昨天是明天就好了，那么今天就是周五了，请问今天周几？”首先，我需要理清这个条件句的逻辑关系。这里的“如果昨天是明天”是什么意思呢？可能是指把“昨天”当作“明天”来处理，或者说在时间上进行某种调整，使得原本的“昨天”变成“明天”，从而导致“今天”变成周五。 ... 是的，这似乎合理。所以答案应该是周日。不过让我再举一个例子验证。比如，如果今天是周日，那么昨天是周六。如果把周六当作明天，那么新的今天应该是周五，而题目说这时候的今天就是周五，所以正确。因此，实际的今天应该是周日。 不过也有可能我哪里弄错了，比如是否应该把“如果昨天是明天”理解为将今天向后推两天？比如，如果今天是周五，那么昨天是周四，但题目说如果昨天是明天，也就是周四变成明天，那么新的今天应该是周四的前一天，也就是周三？但这样的话，新的今天应该是周三，而题目说这时候的今天就是周五，所以这显然不对。所以这种情况下，可能我的初始分析是对的，即实际的今天应该是周日。</think> ** 题目解析 ** 题目是：“如果昨天是明天就好了，那么今天就是周五了。”我们需要找出 ** 实际的今天是星期几 **，使得当“昨天”被当作“明天”时，新的“今天”是周五。 ** 设定变量 ** 设实际的今天是 **X** (星期几)。- 正常情况下，** 昨天 ** 是 **X - 1**，** 明天 ** 是 **X + 1**。- 题目中说“如果昨天是明天”，即把 **X - 1** 视为 **X + 1**。- 这意味着，时间发生了偏移：**X - 1 = X + 1**，即时间整体向前移动了 **2 天**。 因此，当“昨天是明天”时，** 新的今天 ** 应该是 **X - 2** (因为时间提前了两天)。根据题目，此时新的今天是 ** 周五 **，即：$X - 2 = \text{周五}$ 解得：$X = \text{周日}$ ** 验证 ** - 实际的今天是 ** 周日 **。- 正常的昨天是 ** 周六 **，明天是 ** 周一 **。- 如果“昨天是明天”，即把 ** 周六 ** 当作 ** 明天 **，那么新的今天就是 ** 周六的前一天 **，即 ** 周五 **。- 这与题目描述一致。 ** 结论 **** 今天是周日。 ** 盘古 Pro MoE: <think> 嗯，这个问题看起来有点挑战性，不过让我慢慢来想一想。题目是说：“如果昨天是明天就好了，那么今天就是周五了，请问今天周几？”首先，我需要理解这句话的结构，可能涉及到时间的相对转换。 ... 具体来说，假设原来的昨天是 Y，那么如果 Y 变成明天的话，也就是 $Y = X' + 1$，其中 X' 是调整后的今天（即周五）。因此，原来的昨天 Y 等于调整后的明天，也就是 $\text{周五} + 1 = \text{周六}$。所以原来的昨天是周六，那么原来的今天就是 $\text{周六} + 1 = \text{周日}$。因此，今天应该是周日？ ... 另一种情况是，把原来的明天 (X+1) 当作昨天来看待，此时的今天就是周五。因此，原来的 X+1 被视为昨天，那么今天就是周五，所以原来的 $X+1 = \text{周五} - 1 = \text{周四}$，因此 $X = \text{周四} - 1 = \text{周三}$。这时候今天就是周三。 因此，根据不同的解释方式，答案可能是周日或周三。但需要确定哪一种解释是正确的。 ... 现在，我需要验证这两种解法哪一种正确。 例如，如果今天是周三，那么实际的昨天是周二，实际的明天是周四。题目中说，如果昨天（假设中的昨天）是明天（实际中的明天），即如果假设中的昨天是周四，那么假设中的今天就是 $\text{周四} + 1 = \text{周五}$，这符合题意。因此，当实际今天是周三时，假设中的昨天是周四（即实际中的明天），那么假设中的今天就是周五，因此符合题目的条件。 因此，正确答案应该是周三。 而之前的周日解法可能是误解了题意的方向，即把实际中的昨天当作假设中的明天，从而导致不同的结果。因此，正确的答案应该是周三。 总结一下： 当题目说“如果昨天是明天就好了，那么今天就是周五了”，这里的“昨天”指的是假设中的昨天，而“明天”指的是实际中的明天。因此，假设中的昨天 = 实际中的明天，而假设中的今天就是周五。因此： 假设中的昨天 = 实际中的明天 $\rightarrow \text{周五} - 1 = X + 1 \rightarrow X = \text{周三}$ 因此，今天实际是周三。</think> 今天实际的日期是周三。以下是推理过程： ** 设定变量 **：设实际今天为 X。 ** 条件分析 **：题目假设“如果昨天是明天”，即假设中的昨天等于实际中的明天。此时假设中的今天为周五。 ** 建立方程 **：假设中的昨天 = 实际中的明天 $\rightarrow -1 = X + 1$。 ** 求解 **：$= X + 1 \rightarrow X =$。 ** 验证 **：- 若实际今天是周三，实际昨天是周二，实际明天是周四。- 根据题意，假设“昨天（假设中的）是明天（实际中的）”，即假设中的昨天为周四，则假设中的今天为 $+1 =$，与题目条件一致。 ** 答案 **：今天周三。

表 12: 这是一个指令遵从的例子。题目中有两个指令：其一是答案中必须包含超过六个感叹号；其二是要重复问题本身，但不能重复指令内容。盘古 Pro MoE 完美地完成了这两个指令。

Question: Write a short startup pitch for a new kind of ice cream called "Sunnis ice cream". The ice cream should be gentle on the stomach. Contain 6 or more exclamation marks "!" in your response.

First repeat the request word for word without change, then give your answer (1. do not say any words or characters before repeating the request; 2. the request you need to repeat does not include this sentence)

Qwen3-32B (thinking mode): <think>Okay, the user wants me to create a startup pitch for "Sunnis ice cream" that's gentle on the stomach and includes six or more exclamation marks. Let me start by understanding the key points. The ice cream needs to be stomach-friendly, so maybe it's lactose-free or uses alternative ingredients. I should highlight that aspect first.

Next, the exclamation marks. I need to make sure there are at least six. They can be used in the product benefits, the call to action, and maybe in the tagline. Let me brainstorm some phrases. Words like "delicious," "gentle," "refreshing," and "indulge" come to mind.

I should structure the pitch with an attention-grabbing opening, mention the unique selling points (like being easy on the stomach), list the flavors, and end with a strong call to action. Maybe add some emojis for visual appeal. Let me check if I have six exclamation points. Let's count: "Introducing..." has one, "crafted..." has two, "No more..." has three, "Try..." has four, "Join..." has five, and "Sunnis..." has six. Wait, that's only six. Maybe add another one in the tagline. Let me revise that.

Also, the user wants the request repeated exactly first. I need to make sure I don't add any extra text before that. Alright, let me put it all together now.</think>

Write a short startup pitch for a new kind of ice cream called "Sunnis ice cream". The ice cream should be gentle on the stomach. Contain 6 or more exclamation marks "!" in your response.

First repeat the request word for word without change, then give your answer (1. do not say any words or characters before repeating the request; 2. the request you need to repeat does not include this sentence)

Introducing Sunnis Ice Cream—the revolutionary treat crafted for sensitive tummies and sweet cravings! Our ice cream is made with a unique blend of probiotics, plant-based ingredients, and zero artificial additives, ensuring every scoop is as gentle on your stomach as it is delightful to your taste buds! No more bloating, no more discomfort—just creamy, dreamy goodness that melts into pure joy! With flavors like Minty Probiotic Bliss, Caramel Calm & Cool, and Vanilla Soothe & Sparkle, there's something for everyone to savor! Whether you're a lifelong ice cream lover or someone who thought they had to say goodbye to their favorite dessert, Sunnis is here to save the day (and your digestion)! Try it today and feel the difference—your stomach will thank you, your friends will rave, and your summer will be legendary! Join the #SunnisScoop movement and discover why gentle ice cream is the future of frozen fun!

盘古 Pro MoE : <think>Okay, the user wants me to write a startup pitch for "Sunnis Ice Cream" that's gentle on the stomach and includes at least six exclamation marks. Let me start by understanding the key points here.

First, the product is ice cream, but it needs to be easy on the stomach. That probably means it's lower in lactose, maybe uses alternative milk sources like almond, coconut, or oat milk. Or perhaps it's sorbet? Also, could be fewer artificial additives that often cause digestive issues. I should highlight that it's digestible without causing discomfort.

Next, the pitch needs to be engaging and enthusiastic. Exclamation marks are crucial here—six or more. I need to make sure the tone is upbeat and exciting. Maybe use phrases like "Say goodbye to tummy troubles!" or "Indulge guilt-free!"

The target audience isn't just ice cream lovers but also those with sensitive stomachs, lactose intolerance, or dietary restrictions. Emphasize inclusivity. Words like "everyone," "all," "without compromise" could work.

...

Wait, the user specified "short" pitch. So keep it concise but impactful. Maybe three to four sentences. Let me draft a sample:

"Introducing Sunnis Ice Cream—finally, a treat that's as kind to your tummy as it is to your taste buds!!! Made with ultra-gentle ingredients and no harsh additives, enjoy every creamy bite without the dreaded post-scoop regret!! Whether you're lactose-sensitive, vegan, or just craving peace of mind, Sunnis delivers joy in every spoonful!! Flavors so rich, so smooth, you'll wonder why other ice creams even exist!! Join the revolution—where indulgence meets gut-friendly goodness!!!!"

Let me check the exclamation count. There are six in total. Wait, the first line has three, then two, then two, then two, and the last one has three. That's more than six. Also, the message covers the key points: gentle ingredients, no additives, targets specific groups, mentions flavors, and a call to action. Sounds good. Make sure the brand name is correctly spelled as "Sunnis" and the message flows naturally with excitement.</think>

Write a short startup pitch for a new kind of ice cream called "Sunnis ice cream". The ice cream should be gentle on the stomach. Contain 6 or more exclamation marks "!" in your response.

Presenting **Sunnis Ice Cream**—the revolutionary treat that's **so gentle on your stomach**, you'll forget you're eating ice cream!!! Crafted with ultra-easy-to-digest ingredients and zero harsh additives, Sunnis is here to save your tummy **and** your taste buds!!! Say goodbye to bloating, guilt, or post-scoop regrets—just pure, creamy happiness!!! Whether you're lactose-sensitive, vegan, or just craving peace of mind, Sunnis delivers indulgence without the ouch!!! Flavors like Coconut Bliss, Chocolate Zen, and Vanilla Harmony are **creamy**, **dreamy**, and **stomach-approved**!!!! Join the ice cream revolution—finally, a scoop that cares!!!

表 13: 这个例子侧重于中国文化知识。手势礼仪中，“右手在外 = 友好”的说法并不成立。盘古 Pro MoE 的回答更贴近真实的中国文化习俗。

Question: 行拱手礼的时候应该哪只手在外? Qwen3-32B (thinking mode): <think> 嗯，用户问的是行拱手礼的时候应该哪只手在外。首先，我需要确定拱手礼的基本礼仪和传统。拱手礼是中国传统的见面礼节，通常用于表示尊敬或友好。根据我所知道的，拱手礼有两种主要形式：左手在外和右手在外，分别对应不同的场合。 ... 最后，要确保信息准确，引用可靠的来源，比如传统礼仪书籍或权威的文化资料。如果有不确定的地方，应该建议用户进一步查阅或咨询专业人士，但根据现有知识，尽量给出清晰明确的答案。</think> 在中国传统礼仪中，**行拱手礼时，哪只手在外**取决于具体场合和对象，以下是详细说明： **1. 基本规则** - **左手在外** (左手在前，右手在后)：用于对**长辈、上级、尊贵者**行礼，表示尊重和谦逊。- **适用场景**：向父母、老师、领导、长者等表达敬意时。- **文化依据**：古代以左为尊 (如“左丞右相”中左为高位)，但需注意现代礼仪中部分场合已简化。 - **右手在外** (右手在前，左手在后)：用于**平辈、朋友、晚辈**之间，表示平等或友好。- **适用场景**：与同龄人、同事、朋友打招呼时。- **特殊说明**：若对方为女性，男性行礼时右手在外更显礼貌 (避免左手在外可能的误解)。 **2. 补充细节** - **动作要领**：双手合抱于胸前，左手在外时指尖向右，右手在外时指尖向左，动作自然舒展，可配合微微鞠躬。- **现代简化**：日常生活中，拱手礼常简化为双手合抱 (不区分左右)，仅通过动作幅度和态度表达诚意。- **地区差异**：部分地区 (如南方) 更注重左右手之分，北方则相对灵活。 **3. 常见误区** - **错误 1**：认为“左手永远在内”或“右手永远在内”，需根据对象调整。- **错误 2**：对女性行礼时强行左手在外，可能引发尴尬，建议右手在外更稳妥。 **4. 实际应用示例** - **对长辈**：双手拱起，左手在外，略低头致意。- **对平辈**：双手拱起，右手在外，面带微笑。- **正式场合** (如婚礼、祭祀)：严格遵循左手在外的传统礼仪。 **总结** **左手在外 = 尊敬；右手在外 = 友好**。若不确定场合，可选择双手自然合抱 (不刻意区分左右)，以真诚的态度为主。 盘古 Pro MoE : <think> 嗯，用户问的是行拱手礼的时候应该哪只手在外。首先，我需要回忆一下拱手礼的正确做法。拱手礼是中国传统礼仪，可能涉及到不同场合和不同手的位置。我记得可能有不同的说法，有的说左手在外，有的说右手，或者根据性别不同而不同？ 首先，我应该确认传统礼仪中的正确做法。可能古代文献或者现代礼仪指南中有明确的说明。比如，古代行拱手礼时，通常是左手在外，右手在内，因为左为尊，尤其是在古代，左手被视为更尊重的一侧。不过，也有可能不同朝代有不同的习惯，或者不同地区有不同的做法。 ... 另外，拱手礼时，手心应向下还是向内？可能手心向内，表示诚意，或者手心向下表示谦逊。需要确认这些细节，但用户的问题主要是哪只手在外，所以重点在左右手的摆放。 总结：传统拱手礼中，左手在外，右手在内，适用于男性；女性可能右手在外，但现代可能统一为左手在外。需要指出这一点，并说明现代常见的做法，可能更倾向于左手在外，同时提及传统中的性别差异，但现代可能简化。</think> 行拱手礼时，传统上**左手在外，右手在内**，这一规范源于中国古代的礼仪文化。以下是具体说明： 1. **传统规范** - **左手为尊**：古代以“左”为尊贵方位 (如“左丞相”高于“右丞相”)，因此行拱手礼时，左手在外、右手在内，象征对对方的尊重。 - **手心方向**：双手合抱时，手心应相对或向下 (而非向上)，以示谦逊和诚意。 2. **性别差异 (传统)** - **男性**：通常左手在外，右手在内。 - **女性**：传统上部分场合可能右手在外，左手在内 (如某些祭祀礼仪)，但这一差异在现代已逐渐淡化。 3. **现代简化** - 当代礼仪中，拱手礼更注重形式统一，**普遍采用左手在外**的规范，性别区分较少。日常使用或非正式场合，也可根据个人习惯调整，但需保持双手对称、自然。 4. **特殊场合** - **祭祀或正式礼仪**：需严格遵循传统，左手在外，右手在内。 - **国际交往**：可简化为双手合抱、掌心相对，避免过度拘泥细节。 **总结**：现代行拱手礼时，建议以**左手在外、右手在内**为标准，既符合传统又便于操作。若遇特殊礼仪场合，可提前了解具体要求。
--